

Аннотация

Задача анализа данных большой размерности в условиях недостаточности сэмплов, пропуска признаков, особенно актуальна в медицине, где обследованных пациентов немного, а размерность медицинских анализов, кардиограммы, данных fMRI, EEG и т.д. — большие. В таком случае традиционные модели машинного обучения (бустинги, бэггинги, нейронные сети) плохо применимы по двум причинам. Во-первых, они склонны к переобучению, т.к. размерность числа признаков большая, а размерность датасета — малая. Во-вторых, они плохо интерпретируемы, что особенно важно для медицинских ассистентов, при пользовании которыми врач должен понимать, какая именно аномалия указывает на наличие заболевания, а не только получить одну лишь вероятность. Данные задачи будут решены с помощью одного из хорошо интерпретируемых методов — синолитических сетей. Мы покажем их превосходство относительно классических ML- и DL-алгоритмов, исследуем их свойства, поведение на синтетических данных. Введем из мат. теорию, обобщим подходы, а также применим для классификации временных рядов. Новизна работы будет заключаться в 1) новых топологических признаках 2) применении персистентных бар-кодов 3) мат. теории синолитики 4) исследованию устойчивости предложенных алгоритмов при уменьшении размера датасета, зашумления признаков, добавлении шумных признаков 5) применении синолитических графов к классификации временных рядов.

Ключевые слова: synolitic graphs; parenclitic graphs,;

Содержание

1	Введение	4
2	Постановка задачи	9
2.1	Снижение размерности данных.	10
2.2	Снижение с помощью parenclitic networks. Построение графа.	10
2.3	Parenclitic Networks: шаг 2: итоговая классификация	14
2.4	О генеративном моделировании с помощью parenclitic networks и гипер- ребрах	20
2.5	Снижение размерности с помощью synolitic networks. Построение графа .	23
3	Эксперимент 1: улучшенное генеративное моделирование	25
4	Обработка изображений с помощью parenclitic и synolitic networks	30
5	Обработка временных рядов с помощью parenclitic и synolitic networks	30
6	О генеративном и дискриминативном моделировании	30

1 Введение

В эру стремительного развития цифровой экономики, все больше данных собирается и все выше модальность этих данных во всех сферах деятельности человека: в медицине (точечные результаты анализов крови, историй болезни пациентов; временные ряды сенсорных данных ЭКГ, артериального давления, пульса, температуры; изображения рентгеновских снимков, МРТ, УЗИ; аудио и видеоданные), в социальной сфере (тексты постов в соцсетях, результаты опросов; аудио-записи интервью; фотографии событий; видеоданные), в научной сфере (численные данные экспериментов; спектральные данные, микроскопические изображения; геномные и молекулярные данные), в бизнесе (данные транзакций; текстовые отзывы; изображения продуктов; аудио звонки; видео аналитика).

Высокоразмерные и многомодальные данные избыточны, что представляет сложность для их эффективной обработки и использования. В работе решается задача снижения размерности признакового описания объекта. Ее базовый принцип состоит в том, чтобы отобразить высокоразмерное признаковое пространство в низкоразмерное, сохраняя важную информацию о данных (Jia et al., 2022).

На текущий момент известно много методов снижения размерности данных. В работе Örnek and Vural (2019) снижения размерности достигается за счет построения дифференцируемой функции эмбединга в низкоразмерное представление, а в Cunningham and Yu (2014) обсуждаются линейные методы. В работе Isachenko and Strijov (2022) задача снижения размерности решается для предсказания движения конечностей человека по электрокортикограмме с использованием метода QPFS (quadratic programming feature selection), учитывающем мультикоррелированность и входных, и целевых признаков.

Наряду с задачей снижения размерности входных данных стоит задача выбора оптимальной структуры модели. В случае оптимизации структуры нейросети, большое внимание уделено изучению признакового пространства модели. В работах Hassibi et al. (1993) и Dong et al. (2017) применяется метод OBS (Optimal Brain Surgeon), состоящий в удалении весов сети с сохранением ее качества аппроксимации, причем выбор удаляемых весов производится с помощью вычисления гессиана функции ошибки по весам.

В статье Грабовой et al. (2019) приводится метод первого порядка, решающий задачу удаления весов, основанный на нахождении дисперсии градиента функции ошибки по параметру и анализе ковариационной матрицы параметров, а в статье Грабовой et al.

(2020) нерелевантные веса не удаляют, а прекращают их обучение.

Однако представленные выше способы снижения размерности данных и выбора оптимальной структуры модели обладают существенным недостатком: функция отображения в низкоразмерное пространство должна быть дифференцируемой и должна выучиться на основе данных. Поэтому в случаях, когда обучающих данных мало, когда в них есть пропуски, эти алгоритмы могут являться ограниченно применимыми. Другой недостаток состоит в том, что такие алгоритмы сложно интерпретировать [ПРОДОЛЖИТЬ МЫСЛЬ!!!]

Наряду с дифференцируемым отображением в пространство низкой размерности существуют методы недифференцируемого отображения в дискретные структуры. Преимущества таких подходов в том, что они, напротив, работают и на малом количестве данных, они интерпретируемы и их удобно визуализировать, что повышает доверие к результатам, особенно при работе алгоритмов в качестве ассистента человека-специалиста.

Одним из самых наглядных методов представления высокоразмерных данных являются графы (а также ориентированные, взвешенные и гиперграфы). С их помощью можно выделить и визуализировать признаки, их взаимосвязи друг с другом: через веса ребер, кластерную структуру, топологические индексы. Таким образом, снижение размерности достигается в два этапа: на первом по признакам объекта строится граф, на втором из графа извлекаются топологические признаки, которые и используются в дальнейшем для решения исходной задачи.

[ЗАМЕЧАНИЕ: ДОБАВИТЬ ИНФОРМАЦИЮ, КАКУЮ ЗАДАЧУ РЕШАЛИ АВТОРЫ, КАКИЕ ДАННЫЕ ИСПОЛЬЗОВАЛИ, КАК РАЗДЕЛЯЛИ НА ТЕСТ-КОНТРОЛЬ И ПО КАКОЙ ЧАСТИ ОБУЧАЛИ ПЕРВИЧНЫЕ ПРЕДСКАЗАТЕЛИ] Одной из основных статей в этой теме является статья (Zanin and Boccaletti, 2011). В ней авторы предложили подход *parenclitic network representation* от греч. слова *отклонение*. Авторы по каждому объекту, описанному признаками, строят граф, в котором вершины — это признаки, а веса ребер — прямо пропорциональны отклонению от линейной регрессии в задаче предсказания одного признака по другому. Интерпретация простая: чем меньше вес ребра между признаками, тем они созависимее, чем больше — тем независимее. Таким образом, если два признака сильно линейно скоррелированы, то вес ребра между ними будет ≈ 0 . Такой подход (LRPA — linear regression parenclitic approach) — имеет недостаток в том, что учитывает только линейные созависимости. Потому, если один признак от другого зависит, например, квадратично, то вес может быть ненулевой,

что не дает возможности интерпретировать граф корректно. В той же статье авторы предложили другой подход (KDEPA — kernel density estimator parenclitic approach), который решил проблему нелинейности, но плохо обобщался на out-of-sample данные.

Идея *parenclitic network representation* получила развитие в работе (Krivonosov et al., 2020), где предложен новый вариант *parenclitic network* названный *synolitic network* от греч. слова "ансамбль" (Nazarenko et al., 2021). В подходе *synolitic networks* ребра вес ребра определяется относительно конкретной задачи бинарной классификации объектов. Вес ребра Между парой признаков пропорционален вероятностному расстоянию [ЭТО ТАК??] от объекта до границы классификации при использовании только этих двух признаков.

В работе (Demichev et al., 2022) подход *synolitic network* использовался для предсказания выживания пациентов, тяжело больных Covid-19, для правильного распределения лекарств и технических ресурсов. [СТОИТ ЛИ ПИСАТЬ ЕЩЕ О (Sushentsev et al., 2022)???

В работе Nazarenko et al. (2021) было представлено подробное сравнение подходов *synolitic wSA* (weighted synolitic approach) и *parenclitic* (wLRPA, wKDEPA) в задачах бинарной классификации. В качестве данных авторы использовали как синтетические (N —мерные идеальные сферы; "шумные" сферы: добавлено 50 шумовых признаков; "сломанные сферы в которых половина координат зашумлены), так и реальные датасеты (16 датасетов из <https://archive.ics.uci.edu>). Для синтетических датасетов сфер *контрольная группа* (здоровые пациенты) соответствовали точкам с радиусом $0.01 \leq R < 0.5$, а *тестовая группа* (больные) радиусу $0.5 \leq R \leq 1$. Для сравнения алгоритмов авторы изучали *описательные статистики* ($min, max, std, coefvar$) *монологических индексов* (closeness, betweenness, edge betweenness, page rank, eigen centrality, authority score, strength, edge weights) и полного вектора взвешенных степеней вершин. В случае синтетического датасета авторы изучали корреляцию таких числовых признаков с радиусом, а на реальных данных сравнивали точность ML-моделей построенных на признаках выше с построенными на сырых признаках (Nazarenko et al., 2021). Авторы статьи показали, что подход wSA имеет преимущество над LRPA и KDEPA как на синтетических данных (у wSA большее число признаков скоррелировано с радиусом), так и на реальных данных (ML-модели, построенные на весах вершин дают больший ROC AUC по сравнению с построенными на сырых данных; степени вершин wSA дают лучшее качество, чем других подходов; разница test AUC на сырых и на данных степеней вершин стат. значимо < 0 у wSA на большем числе датасетов, чем у других

подходов) (Nazarenko et al., 2021). Авторы также показали, что wSA подход показывает стат. значимые преимущества при **размере train меньше, чем число признаков**.

Авторы статьи (Krivonosov et al., 2022) использовали *synolitic networks approach* для изучения синдрома дауна: предсказывали его наличие и сравнивали топологические признаки больного, его здоровых братьев и сестер, его матери. Граф строился следующим образом: для каждой пары признаков тренировался бинарный классификатор (болен-здоров), далее ребра, соответствующие классификаторам с точностью $> 75\%$ удалялись из графа, а веса остальных ребер вычисляли, как вероятность быть "больным". Интерпретируемость метода *synolitic networks* (сравнение топологических признаков) позволил авторам подтвердить гипотезу ускоренного старения: больные синдромом дауна по признакам были более похожи на мать, чем на братьев и со взрослением это сходство увеличивалось (Krivonosov et al., 2022).

Авторы статьи (Krivonosov et al., 2024) и предложили улучшение подхода *synolitic networks approach* с использованием архитектуры Synolitical Graph Neural Networks (SGNN). Синтетические данные (сферы) были такими же, как и в статье (Nazarenko et al., 2021), в качестве реальных данных взяты fMRI-снимки. Авторы предлагают два подхода к построению *Synolotic graph*: для не пространственных данных каждые два признака соединяются ребром, вес которого равен вероятности принадлежности объекта к одному из классов, полученной из соответствующего классификатора (radial SVM kernel). Для пространственных данных (картинок, fMRI-снимков) ребра проводятся между каждой парой соседних вокселей в решетке, а вес ребра назначается как разность вероятностей принадлежности к первому и второму классу: $w_{i,j} = P(|v_i, v_j) - P(|v_i, v_j)$. Далее с помощью Convolutional GNN для каждой вершины находился эмбединг, затем авторы применили Global Max Pooling и классифицировали полученный эмбединг.

В недавней статье (Vlasenko et al., 2024) авторы тоже используют *Graph Synolitic Neural Network* подход для бинарной классификации активности человека по пространственно-временному ряду fMRI. Авторы сравнивают синолитические графы с корреляционными графами (вес ребра равен коэффициенту корреляции) и приходят к выводу, что синолитические дают лучшую точность классификации, более устойчивы к шумам в fMRI данных. Авторы с помощью парцеляционного атласа головного мозга, представленного в работе (Glasser et al., 2016) разделили его на 379 регионов. Далее fMRI-данные по каждому из регионов преобразовывались в один скалярный временной ряд двумя способами: 1) усреднением соответствующих временных рядов вокселей 2) извлечением 1-ой компоненты PCA, построенного на матрице (воксели, время). Вес каждого ребра

задавался как разность вероятностей принадлежности к первому и второму классу, в качестве окончательных признаков вершин использовались средний вес ребер, смежных с вершиной. Авторы также разработали методологию кросс-валидации при которой в 2-х стадийном обучении SGNN нет утечки тестовых данных. Кроме того, с помощью алгоритма force-directed Fruchterman-Reingold они визуализировали матрицы весов для разных состояний мозга таким образом, что классификация становится очевидной.

[ВКРАТЦЕ ОПИСАТЬ, В ЧЕМ ПРЕИМУЩЕСТВО СИНОЛИТИКИ ПЕРЕД ПА-РЕНКЛИТИКОЙ И ЧТО В ДАЛЬНЕЙШЕМ ИМЕННО СИНОЛИТИКУ МЫ И БУ-ДЕМ ИССЛЕДОВАТЬ]

Приведенные выше задачи снижения размерности данных и выбора оптимальной структуры нейросети основаны на исследовании пространства входных данных и пространства признаков соответственно. Существенный недостаток предыдущих работ состоит в том, что в них анализируются *отдельные* параметры (скаляры) моделей и их взаимозависимость. Тем самым не учитывается, что на входные данные действуют *векторы* параметров посредством скалярных произведений, то есть упускается из виду простая *структура* преобразования.

В данной работе решается задача восстановления временного ряда, в рамках которой исследуем проблему снижения размерности пространства параметров модели. Снижение размерности основано на анализе сопряженного пространства ко входному. Оно связывает входное пространство и пространство параметров.

В данном исследовании мы будем рассматривать нейросети простейшей структуры - которые являются композицией линейных и простых нелинейных функций (функций активации). Их составной блок описан формой:

$$\mathbf{y} = \sigma(\mathbf{W}\mathbf{x} + \mathbf{b}), \mathbf{y}, \mathbf{b} \in \mathbb{R}^m, \mathbf{x} \in \mathbb{R}^n, \mathbf{W} \in \mathbb{R}^{m \times n}, \sigma : \mathbb{R} \rightarrow \mathbb{R}.$$

Из-за глобального потепления арктический лед утончается, вследствие чего период навигации в арктических водах увеличивается. Эти воды используются в сферах туризма, бизнеса, науки. В любом случае это использование связано с перемещением по этим водам, то есть навигацией. В отличие от навигации в средних широтах, основной проблемой северной навигации являются плавающие льды, которые в зимний период останавливают ее почти полностью, а в летний допускают с ограничениями. Причина тому — сложность планирования маршрута, связанная с опасностью столкновения с плавающими льдинами.

На текущий момент повсеместно используются ледовые карты, дающие информа-

цию как о структуре плавучих льдов, так и о их месторасположении. К структуре льдов относят их геометрические свойства (трещины, разводья, полыньи) и физические свойства (возраст, состав). Капитан судна, имея информацию о структуре и географическом положении льдин, оценивает риски и принимает решение о том, является ли судоходным данный участок маршрута и как его проходить [ers](#).

Ледовые карты в прошлом составлялись экспертами вручную путем анализа данных дистанционного зондирования Земли, получаемых от спутников на орбите. Проводимый вручную, этот анализ занимал большое количество времени, что вносило ограничения применимости [Sandven et al. \(2023\)](#). В последнее время были разработаны нейросетевые методы детектирования льдов на фоне воды и неба, их структурного анализа и предсказания их движения.

В работе решается задача предсказания движения ледников на основе спутниковых снимков Sentinel-1 SAR. Она рассматривается в рамках задачи предсказания видео. Для задачи предсказания видео применяются рекуррентные, сверточно-рекуррентные архитектуры ([Grigoryev et al. \(2022\)](#), [Shi et al. \(2015\)](#), [Yuan and Dai \(2022\)](#)), а так же диффузионные, вариационные и генеративно-состязательные ([Yang et al. \(2023\)](#), [Höppe et al. \(2022\)](#), [Voleti et al. \(2022\)](#), [Chung et al. \(2015\)](#), [Castrejon et al. \(2019\)](#), [Ji et al. \(2022\)](#), [Seo et al. \(2022\)](#)) модели.

Приведенные выше методы требуют, чтобы данные были без пропусков, поэтому в работе используются те их них, которые могут быть избавлены от этого недостатка с помощью разработанного авторами separable подхода: ConvLSTM, U-net ConvLSTM.

2 Постановка задачи

- Рассказать про Паренклитику и Синолитику (с формулами), про GNNs, Convolutional GNN, Attention GNN (взять из <https://arxiv.org/pdf/2305.05601> и <https://arxiv.org/pdf/2104.1347>)

- Рассказать про топологические индексы, теорию графов.

Решается задача бинарной классификации данных.

Данные: $\mathcal{D} = \{(\mathbf{x}_i, y_i)\}_{i=1}^N, \mathbf{x} \in \mathbb{R}^D, y \in \{0, 1\}$.

Предположение о генерации данных: $(\mathbf{x}, y) \sim p(\mathbf{x}, y) = p(\mathbf{x}) \cdot p(y|\mathbf{x})$.

Модель данных: $p(y|\mathbf{x}) \approx p(y|\mathbf{x}, \theta); p(y = 1|\mathbf{x}, \theta) = f(\mathbf{x}, \theta) = f_\theta(\mathbf{x})$.

Оптимизируемый критерий:

$$\mathcal{L}(\theta, \mathcal{D}) = \sum_{i=1}^N y_i \cdot \log p(y = 1|\mathbf{x}, \theta) + (1 - y_i) \cdot \log(1 - p(y = 1|\mathbf{x}, \theta)) \rightarrow \max_{\theta}$$

Выбор модели из семейства: Считаем, что $f_\theta(\mathbf{x}) \in \mathcal{F} = \{f_\theta, \theta \in \Theta\}$ — принадлежит некоторому параметрическому семейству.

Специфика данных: размерность данных достаточно большая по сравнению с их количеством: $D > N$, что ограничивает применимость стандартных моделей, т.к. может привести к их переобучению.

2.1 Снижение размерности данных.

Так как размерность данных большая, то стандартным приемом является снижение размерности данных, после чего в новом пространстве задача классификации решается стандартными ML-методам.

Таким образом, функция $f_\theta(\mathbf{x})$ ищется в виде композиции функций снижения размерности и классификации:

$$\begin{aligned}\mathbf{z} &= F_\theta(\mathbf{x}) : \mathbb{R}^D \rightarrow \mathbb{R}^d \\ f_\theta(\mathbf{x}) &= q_\theta(\mathbf{z}) = q_\theta(F_\theta(\mathbf{x})) : \mathbb{R}^d \rightarrow [0, 1]\end{aligned}$$

Где $D \gg d$. В качестве функции F_θ могут выступать стандартные средства снижения размерности (Van Der Maaten et al., 2009):

1. PCA, LDA — нет обучаемых параметров, ограничение $N > D$, работают на малых выборках.
2. t-SNE, UMAP — эффективны только на средних/больших выборках, нет обучаемых параметров, ограничение $N > D$.
3. Autoencoder — требует больших датасетов для обучения нейросетей внутри.

Как заметили авторы статьи (Krivonosov et al., 2024), эти стандартные методы в условиях высокоразмерных данных малого количества находят лишь локальные оптимумы и не устойчивы.

2.2 Снижение с помощью parenclitic networks. Построение графа.

Совершенно другой подход снижения данных, а точнее другого их представления используют авторы статьи (Zanin and Boccaletti, 2011) — паренклитический.

Опишем сначала построение графа по алгоритму LDPA, веса ребер которого рассчитываются как расстояние до выученной линейной регрессии, а затем обобщим паренклитический метод.

Паренклитический метод решает задачу бинарной классификации данных и для построения графа делит их на две части: контроль (группа 0, здоровые) и тест (группа 1, больные):

$$\begin{cases} \mathcal{D} = \{(\mathbf{x}_i, y_i)\}_{i=1}^N = \mathcal{D}_0 \sqcup \mathcal{D}_1; \\ \mathcal{D}_0 = \{(\mathbf{x}, y) \in \mathcal{D} : y = 0\}; \\ \mathcal{D}_1 = \{(\mathbf{x}, y) \in \mathcal{D} : y = 1\}; \end{cases}$$

Далее на контрольной группе обучается система линейных регрессий, предсказывающая по одному признаку объекта другой:

$$\begin{cases} \mathcal{T}_{\mathcal{D}_0}^\theta = \{f_{i,j}^\theta : \mathbb{R}^D \rightarrow \mathbb{R}^D; f_{i,j}^\theta(x_i) = \alpha_{i,j}^\theta + \beta_{i,j}^\theta \cdot x_i\} \\ \mathcal{L}(\theta) = \mathbb{E}_{x \in \mathcal{D}_0} \sum_{i,j} |f_{i,j}^\theta(x_i) - x_j| \rightarrow \min_{\theta} \\ f_{i,j}^\theta(x) = \theta_b^{i,j} + \theta_a^{i,j} \cdot x \text{ (линейная регрессия)} \\ \mathcal{L}(\theta) = \sum_{x \in \mathcal{D}_0} \sum_{i,j} |x_j - (\theta_b^{i,j} + \theta_a^{i,j} \cdot x_i)| \rightarrow \min_{\theta} \end{cases} \quad (1)$$

Полученная система линейных регрессий $\mathcal{T}_{\mathcal{D}_0}^\theta$ используется для преобразования объекта $\mathbf{x}$ в матрицу смежности соответственного взвешенного неориентированного графа $A^{\mathbf{x}} \in \mathbb{R}^D \times \mathbb{R}^D$:

$$\begin{cases} \mathcal{T}_{\mathcal{D}_0}^\theta(\mathbf{x}) = A^{\mathbf{x}} \\ A_{i,j}^{\mathbf{x}} = w_{i,j}^{\mathbf{x}} = |f_{i,j}^\theta(x_i) - x_j| \end{cases}$$

Затем веса перенормировываются на величину стандартного отклонения остатков в контрольной группе и получается результирующая симметричная матрица взвешенного неориентированного графа. Эти этапы выписываться не будут.

Недостатком данного подхода является то, что система 1 не имеет аналитического решения, т.к. распадается на набор не имеющих аналитического решения $L1$ -регрессий:

$$\sum_{i=1}^n |y_i - (ax_i + b)| \rightarrow \min_{a,b}$$

В свою очередь, это затрудняет исследование статистических свойств получаемых графов. Ниже мы дадим обобщение данного подхода.




Рис. 1: Результат построения parenclitic networks (Zanin and Boccaletti, 2011). Зелене графы — здоровый пациент, красные — с патологией. Левый столбец — miniRNA сеть, правый — metabolic сеть.

2.2.1 Обобщение метода parenclitic networks

Здесь мы дадим вероятностную интерпретацию *parenclitic networks*.

Фактически обучение системы каждого классификатора $f_{i,j}^\theta$ аналогично нахождению параметров условного распределения $p^\phi(x_j|x_i, y = 0)$ в семействе вероятностных распределений $\phi \in \Phi = \{\mathcal{N}(\phi_a^{i,j}x_i + \phi_b^{i,j}, (\phi_\sigma^{i,j})^2)\}$, моделирующего эмпирический аналог реального распределения $p(x_j|x_i, y = 0)$ и подбирающего параметры с помощью метода максимального правдоподобия.

В вероятностной постановке логично максимизировать логарифм правдоподобия:

$$\log L = \sum_{\mathbf{x} \in \mathcal{D}_0} \sum_{i,j} \log p^{\phi^{i,j}}(x_j|x_i, y = 0) \rightarrow \max_{\phi \in \Phi}$$

2.2.2 LDPA, или моделирование с помощью распределения Лапласа

Предположим, что остатки линейной регрессии распределены по Лапласу:

$$\begin{cases} x_j = ax_i + b + \xi \\ \xi \sim \text{Lapl}(0, 1) \\ p(\xi) = \frac{1}{2}e^{-|\xi|} \end{cases}$$

Тогда задача максимального правдоподобия для каждой пары (i, j) примет вид:

$$-\log L_{i,j} = n \cdot \log(2) + \frac{1}{2} \sum_{\mathbf{x} \in \mathcal{D}_0} |x_j - (a_{i,j}x_i + b_{i,j})| \rightarrow \min_{a_{i,j}, b_{i,j}}$$

Получилась равно та же постановка задачи, что и в LDPA 1.

2.2.3 Parenclitic networks с нормальным распределением

Как уже говорилось, распределение Лапласа не дает возможности аналитически вычислить решение задачи максимального правдоподобия.

Поэтому, поставим задачу в другом предположении: предположении о нормальности остатков линейной регрессии:

$$\begin{cases} x_j = ax_i + b + \xi \\ \xi \sim \mathcal{N}(0, 1) \\ p(\xi) = \frac{1}{\sqrt{2\pi}}e^{-\frac{|\xi|^2}{2}} \text{ т.к. параметр размерности } 1 \end{cases}$$

Тогда задача максимального правдоподобия для каждой пары (i, j) примет вид:

$$-\log L_{i,j} = n \cdot \log(2\pi) + \frac{1}{2} \sum_{\mathbf{x} \in \mathcal{D}_0} (x_j - (a_{i,j}x_i + b_{i,j}))^2 \rightarrow \min_{a_{i,j}, b_{i,j}}$$

А это уже задача МНК, которая имеет аналитическое решение:

$$\begin{cases} a_{i,j}^* = \frac{n \sum_{\mathbf{x} \in \mathcal{D}_0} x_j \cdot x_i - \left(\sum_{\mathbf{x} \in \mathcal{D}_0} x_i \right) \left(\sum_{\mathbf{x} \in \mathcal{D}_0} x_j \right)}{n \cdot \sum_{\mathbf{x} \in \mathcal{D}_0} x_i^2 - \left(\sum_{\mathbf{x} \in \mathcal{D}_0} x_i \right)^2} \\ b_{i,j}^* = \frac{\sum_{\mathbf{x} \in \mathcal{D}_0} x_j - a_{i,j}^* \cdot \sum_{\mathbf{x} \in \mathcal{D}_0} x_i}{n} \end{cases}$$

Итого, мы получили задачу, похожую на обучение линейных регрессий в LDPA-алгоритме 1, только оптимизируется не первая норма отклонений, а вторая (как в задаче МНК). Что в качестве преимущества дает аналитическое решение.

2.2.4 Другие распределения

1. На какой синтетической задаче normal distribution будет лучше, чем laplace distribution?
— Придумать, показать на графиках преимущество.
2. Какое качество normal distribution в сравнении с laplace distribution на реальных данных? На каких датасетах стат. значимо выигрывает? Какие графы получаются в том и в другом случае?
3. Обобщить на не-скалярные признаки (в изображениях — поля 5x5), на не-линейные зависимости?

2.3 Parenclitic Networks: шаг 2: итоговая классификация

Как было сказано ранее, система обученных на первом шаге регрессоров $f_{i,j}^\theta$ используется для задания весов ребрам графа, соответствующего каждому объекту $\mathbf{x}$:

$$A_{i,j}^{\mathbf{x}} = w_{i,j}^{\mathbf{x}} = |f_{i,j}^\theta(x_i) - x_j|$$

Далее из полученного графа авторы извлекают *топологические признаки* узлов и ребер (Closeness centrality, Eigen centrality, Betweenness centrality, Authority score, Edge betweenness, PageRank, Node weights), а затем их описательные статистики (zeros, min, max, mean, std, coefvar) и уже используют эти признаки для финальной классификации.

Ключевое предположение состоит в следующем: так как система регрессоров обучалась только на контрольной ($y = 0$) группе, то на ней ошибки в предсказании будут минимальными. Поэтому в соответствующем графе веса ребер (а при бинаризации, количество ребер) будет **существенно** меньше на контроле $y = 0$, чем на тесте $y = 1$. Вследствие этого топологии графов будут существенно отличаться и потому с помощью топологических признаков эти графы можно легко различить.

2.3.1 Вероятностная интерпретация

Здесь ключевое предположение переформулируется таким образом:

С учетом того, что сказано выше, веса ребер могут быть вероятностными:

$$\begin{cases} \mathbf{x} \in \mathcal{D}_0 \rightarrow A_{i,j}^{\mathbf{x}} = w_{i,j}^{\mathbf{x}} = p^{\phi^*}(x_j|x_i, y = 0) \\ \mathbf{x} \in \mathcal{D}_1 \rightarrow A_{i,j}^{\mathbf{x}} = w_{i,j}^{\mathbf{x}} = p^{\phi^*}(x_j|x_i, y = 1) \end{cases}$$

Так как теперь для каждой пары признаков мы имеем условные вероятности, мы можем вычислить правдоподобие каждой вершины i (входное и выходное) относительно других:

$$\begin{cases} \text{Likelihood}_{out}(A^{\mathbf{x}}, i) = \prod_{j=1}^n p^{\phi^*}(x_j | x_i, y = 0) \\ \log(\text{Likelihood}_{out}(A^{\mathbf{x}}, i)) = \sum_{j=1}^n p^{\phi^*}(x_j | x_i, y = 0) \\ \text{Likelihood}_{in}(A^{\mathbf{x}}, i) = \prod_{j=1}^n p^{\phi^*}(x_i | x_j, y = 0) \\ \log(\text{Likelihood}_{in}(A^{\mathbf{x}}, i)) = \sum_{j=1}^n p^{\phi^*}(x_i | x_j, y = 0) \end{cases}$$

Заметим, что это ровно то же, что и взвешенные степени вершин в *parenclitic networks*.

А затем совокупное правдоподобие всего графа (как произведения правдоподобия каждой вершины):

$$\begin{cases} \text{Likelihood}(A^{\mathbf{x}}) = \prod_{i=1}^n \text{Likelihood}_{out}(A^{\mathbf{x}}, i) = \prod_{i=1}^n \text{Likelihood}_{in}(A^{\mathbf{x}}, i) \\ \log \text{Likelihood}(A^{\mathbf{x}}) = \sum_{i,j=1}^n \log(p^{\phi^*}(x_j | x_i, y = 0)) \end{cases}$$

Здесь ключевое предположение в том, что плотность вероятности для контрольных объектов $\mathbf{x} \in \mathcal{D}_0$: $p^{\phi^*}(x_j | x_i, y = 0)$ значительно отличается от тестовых объектов $\mathbf{x} \in \mathcal{D}_1$: $p^{\phi^*}(x_j | x_i, y = 1)$. Вследствие этого плотность $p^{\phi^*}(x_j | x_i, y = 0)$ будет большая у точек $\mathbf{x} \in \mathcal{D}_0$ и малая у точек $\mathbf{x} \in \mathcal{D}_1$. То есть на гипотезе, что условные плотности признаков в контроле $\mathcal{D}_0$ и тесте $\mathcal{D}_1$ отличаются значительно.

Ключевое вероятностное предположение: Топологии графов будут существенно различаться, так как правдоподобие графов (вершин, ребер), построенных по объектам из $\mathcal{D}_0$ будет намного больше, чем построенных по объектам из $\mathcal{D}_1$. То есть условные плотности признаков в контроле $\mathcal{D}_0$ и тесте $\mathcal{D}_1$ отличаются значительно.

Как мы видим, отличие в топологии базируется на предположении о различности распределений, большом между ними расстоянии. Например, большой KL-дивергенции.

Как развить дальше:

1. Вероятностная постановка дает возможность учесть и непрерывные, и дискретные признаки — что расширяет применимость.
2. Можно **генерировать** данные *контрольной* группы или **восстанавливать** пропущенные признаки (методом $\max \text{Log Likelihood}$ /aposteriori probability).
3. Можно расширить подход *parenclitic networks* до *contrastive parenclitic networks*:

- Вариант 1: максимизировать отношение правдоподобий объектов из $\mathcal{D})_0$ и $\mathcal{D})_1$ (разность log-правдоподобий) с некоторым коэффициентом c . Это обеспечит большее различие в топологиях графов и позволит использовать для дообучения **все имеющиеся данные, а не только контрольные**.

$$\sum_{i,j} \sum_{\mathbf{x} \in \mathcal{D}_0} \log p^{\phi^{i,j}}(x_j | x_i, y = 0) - c \cdot \sum_{i,j} \sum_{\mathbf{x} \in \mathcal{D}_1} \log p(x_j | x_i, y = 0) \rightarrow \max_{\phi^{i,j}}$$

Замечание: коэффициент c нужно подбирать таким образом, чтобы дискриминант полученных квадратных уравнений (относительно a и b был

- Вариант 2: — учить одновременно $p(x_j | x_i, y = 0)$ и $p(x_j | x_i, y = 1)$, оптимизировать общее правдоподобие + добавить KL-дивергенцию (чтобы распределения отличались по максимуму).

Печальная новость — теоретически метод *parenclitic networks* пока ничего нового не дает — это только байесовский подход к моделированию. Далее можно задавать априорные предположения на признаки, их распределения И делать байесовский вывод апостериорных распределений. [подобное было в курсе по байесам]

2.3.2 Parenclitic Networks. Многоклассовая классификация

Дан набор классов $Y = \{1, \dots, k\}; y \in Y$.

Имеем генеративную модель: $p(\mathbf{x}, y) = p(\mathbf{x} | y) \cdot p(y)$.

Считаем вероятности классов по формуле Байеса: $p(y | \mathbf{x}) = \frac{p(\mathbf{x} | y) \cdot p(y)}{p(\mathbf{x})} = \frac{p(\mathbf{x} | y) \cdot p(y)}{\sum_{y \in Y} p(\mathbf{x} | y) p(y)}$

Где $p(y)$ — априорные вероятности классов.

Тогда для объекта $\mathbf{x}$ выбирается тот класс, вероятность которого максимальна, т.е.:

$$y(\mathbf{x}) = \arg \max_{y \in Y} p(y | \mathbf{x}) = \arg \max_{y \in Y} \frac{p(\mathbf{x} | y) \cdot p(y)}{\sum_{y \in Y} p(\mathbf{x} | y) p(y)} = \arg \max_{y \in Y} p(\mathbf{x} | y) \cdot p(y) = [p(y) \text{ равномерны}] = \arg \max_{y \in Y} p(y)$$

Практически это означает, что для каждого класса нужно выучить функцию плотности и далее их использовать для классификации.

2.3.3 Parenclitic Networks. Байесовский вывод параметров

Для каждого моделируемого распределения $p^\phi(x_j | x_i, y = 0) = \mathcal{N}(\phi_a \cdot x_i + \phi_b, 1)$ выведем апостериорное распределение на ϕ .

Для этого зададим априорное распределение на $\phi : P(\phi)$ и распишем по Байесу апостериорную вероятность:

$$P(\phi|\mathcal{D}_0, y = 0) = P(\mathcal{D}_0|\phi, y = 0) \cdot P(\phi|y = 0)$$

И решим его (аналитически или градиентными методами) для каждой пары вершин независимо.

В результате для каждой пары вершин мы получим распределение на параметры a, b . А, значит, сможем вычислить неопределенность для параметров каждого ребра.

Что это дает?

1. Пример: КРУГ!!! Если ребро имеет высокую дисперсию параметров ϕ_a, ϕ_b , то в нем МАР оценка параметров нестабильна и при небольшом изменении датасета $\mathcal{D}_0$ МАР мог бы сильно измениться. Поэтому данная пара признаков (ребро) не может характеризовать элементы $y = 0$ (здоровых, контроль) и потому для нового $\mathbf{x}$ не сможет отличить случай $y = 0$ и $y = 1$. И потому это ребро ну нужно создавать при построении графа.
2. Заметим, что при $n \rightarrow +\infty$ (растущем числе объектов) $P(\phi|\mathcal{D}_0, y = 0) \rightarrow \phi_{\text{МАР}}$. Поэтому при большом числе объектов замечание из п.1 выше неактуально. Однако в мед. данных всегда недостаточно
3. Заметим, что неопределенность ничего не говорит о качестве предсказания $p(x_j|x_i)$ (его дисперсии). Даже если зависимость $x_j|x_i$ квадратичная, а мы моделируем ее линейной, то дисперсия параметров будет малая, если n велико.

2.3.4 Распределения параметров

В этой секции мы осуществим байесовский вывод распределения параметров паренклитических сетей при моделировании попарных зависимостей линейной регрессией (нормальным распределением).

И ответим на **вопрос**: как распределены веса ребер паренклитического графа?

Генеративная модель задана неявно условиями:

$$\begin{cases} p(x_j|x_i) \sim \mathcal{N}(a_{i,j}x_i + b_{i,j}; \sigma^2) \\ p(x_i, x_j|x_k) = p(x_i|x_k) \cdot p(x_j|x_k); \quad (\text{любые два признака при условии третьего независимы}) \end{cases}$$

Дисперсию σ^2 будем для простоты считать известной.

В таких условиях задача нахождения параметров нормальных распределений и распределений их самих эквивалентна задаче нахождения этих же коэффициентов методом МНК (т.к. индивидуальные плотности мы не оптимизируем, а правдоподобие в силу заданной генеративной модели расписывается симметрично относительно попарных зависимостей).

Также очевидно, что задача нахождения параметров и их распределений решается независимо по ребрам.

Итак, зафиксируем пару $\{i, j\}$. Обозначим:

$$\begin{cases} z = x_j \\ x = \begin{pmatrix} x_i \\ 1 \end{pmatrix} \end{cases}$$

И составим матрицы:

$$Z = \begin{pmatrix} x_j^1 \\ x_j^2 \\ \dots \\ x_j^n \end{pmatrix} \quad X = \begin{pmatrix} x_i^1 & 1 \\ x_i^2 & 1 \\ \dots & \dots \\ x_i^n & 1 \end{pmatrix}$$

Тогда задача линейной регрессии запишется в виде:

$$\begin{cases} Z = X \cdot \theta + \xi \\ \theta = \begin{pmatrix} a & b \end{pmatrix} \\ \xi \sim \mathcal{N}(0, \sigma^2 I) \end{cases}$$

Тогда по известной формуле оптимальные параметры запишутся как:

$$\hat{\theta} = (X^T X)^{-1} X^T Z$$

Веса соответствующего ребра (i, j) для каждого объекта (k) равны квадрату отклонения от линейной регрессии и запишутся как:

$$w_{i,j}^k = (e_{i,j}^k)^2 = \left[Z - X \cdot \hat{\theta} \right]_k^2$$

То есть как квадраты остатков линейной регрессии.

Зададимся вопросом: как они распределены?

Теория линейной регрессии дает ответ:

$$w_{i,j}^k = (e_{i,j}^k)^2 = |x_j^k - x_i^k \cdot \hat{a}_{i,j} - \hat{b}_{i,j}| \sim \sigma^2 \cdot (1 - h_{k,k}) \cdot (\mathcal{N}(0, 1))^2 \sim \sigma^2 \cdot (1 - h_{k,k}) \cdot \chi_1^2$$

Где

$$H = X(X^T X)^{-1} X^T$$

А для нового объекта x^* его остаток $e_{i,j}^* = x_j^* - \hat{a}_{i,j} \cdot x_i^* - \hat{b}_{i,j}$

$$e_{i,j}^* \sim \mathcal{N}(0, [x_i^*, 1] \cdot \sigma^2 (1 + (X^T X)^{-1} \cdot [x_i^*, 1]^T)$$

Если же σ^2 не известно, то можно использовать его оценку (тогда распределения станут студентовскими):

$$\hat{\sigma}^2 = \frac{1}{n-2} \|Z - X \cdot \hat{\theta}\|^2$$

Отсюда же получаем распределение сил вершин для объекта k из выборки (как остатков в регрессии):

$$s^k(i) = \sum_j (e_{i,j}^k)^2 \sim \sum_{j:j \neq i} \sigma^2 \cdot (1 - h_{k,k}) \cdot \chi_1^2 \sim [\text{предполагаем независимость}] \sim \sigma^2 (1 - h_{k,k}) \chi_{d-1}^2$$

Далее ответим на вопрос, подчиняется ли распределение вершин паренклитического графа power-law закону ([Adamic et al., 2001](#)).

Мы выяснили, что распределение степени одной вершины — это взвешенная сумма χ_1^2 распределений с неотрицательными коэффициентами. И, согласно статье ([Zhang and Zhou, 2020](#)) (раздел 4.2, Теорема 6): для взвешенной суммы независимых хи-квадрат распределений $Y = \sum_{i=1}^k u_i \chi_i^2$; $u_i > 0$ мы имеем (для некоторых констант c, C, C_1 :

$$\mathbb{P}(Y > x + \sum_{i=1}^k u_i) \geq c \cdot \exp(-Cx / \|u\|^\infty) \quad \forall x > \frac{\|u\|_2^2}{\|u\|_\infty}$$

То есть хвосты в таком случае убывают не менее чем экспоненциально.

2.3.5 Parenclitic Networks. Байесовская спарсификация

Заметим, что чем меньше неопределенность в параметрах обученной регрессии, тем лучше данная пара признаков "вписывается" в картину здорового человека, чем больше — тем хуже.

Действительно: чем больше дисперсия параметров обученной регрессии, тем больше дисперсия веса соответствующего ребра (при предположении независимости параметров регрессии). А, значит, тем больше дисперсия силы вершины (ее правдоподобия). Следовательно, важнейший топологический признак имеет высокую внутриклассовую дисперсию и потому не пригоден к классификации. Кроме того, и дисперсия суммы степеней вершин, которая равна лог-правдоподобию всего графа, будет иметь высокую дисперсию и потому ...

[ДОБАВИТЬ ТЕКСТ ПРО: РАСПРЕДЕЛЕНИЕ ВЕСОВ ЛИНЕЙНОЙ РЕГРЕССИИ, РАСПРЕДЕЛЕНИЕ ДИСПЕРСИИ ОШИБКИ, РАСПРЕДЕЛЕНИИ ДЛЯ Т-ТЕСТА. ИЗ ЭТОГО ПОНЯТЬ, ЧТО ТАКОЕ ОПТИМАЛЬНАЯ СПАРСИФИКАЦИЯ И ВЫВЕСТИ АЛГОРИТМ ОПТИМАЛЬНОЙ СПАРСИФИКАЦИИ].

Поэтому естественно предположить, что при спарсификации графа в первую очередь нужно удалять ребра с большой неопределенностью в весах. Так как они хуже всего отражают "здоровые" зависимости.

Поэтому,

Алгоритм байесовский спарсификации: ...

2.4 О генеративном моделировании с помощью *parental networks* и гиперребрах

Как мы обсудили выше, в парентклитическом подходе мы моделируем условные распределения $p(x_j|x_i)$. Посмотрим на задачу шире.

Дано: выборка $\mathcal{D} = \{\mathbf{x}_i\}_{i=1}^N; \mathbf{x}_i \in \mathbb{R}^d$.

Найти: распределение $p(\mathbf{x}) = p(x_1, \dots, x_d) \approx p^\phi(x_1, \dots, x_d)$

Критерий: $KL(p, p^\phi) \rightarrow \min_{\phi \in \Phi}$

Ключевым здесь является тип зависимости, которую мы моделируем, т.е. вероятностные свойства функции распределения компонент вектора $p(x_1, \dots, x_n)$.

Начнем с простого случая, когда все компоненты независимы и будем постепенно убирать предположения о независимости.

Шаг 0: предположим, что все компоненты в совокупности независимы, т.е. что

$$p(x_1, \dots, x_d) = p(x_1) \cdot \dots \cdot p(x_n) = P^{(0)}$$

В этом случае логично моделировать распределение каждой компоненты отдельно и потому искать распределение в виде: $p^\phi(x_1, \dots, x_d) = p^{\phi_1}(x_1) \dots p^{\phi_d}(x_d)$ — т.е. обучать d одномерных плотностей.

Шаг 1 (паренклитика): предположим, что компоненты независимы в совокупности, если обусловлены на другую какую-то компоненту, т.е. что $p(x_i, x_j | x_k) = p(x_i | x_k) \cdot p(x_j | x_k)$. (математически строго, что $\forall I \subset \{1, \dots, d\} : i \notin I : p(\mathbf{x}_I | x_i) = \prod_{j \in I} p(x_j | x_i)$).

Тогда для плотности получим выражение: $p(\mathbf{x}) = p(x_1, \dots, x_d) = p(x_2, \dots, x_d | x_1) \cdot p(x_1) = p(x_2 | x_1) \cdot \dots \cdot p(x_d | x_1) \cdot p(x_1)$.

Или, симметризуя, получим:

$$p(\mathbf{x})^d = p(x_1) \cdot \dots \cdot p(x_d) \cdot \prod_{i=1}^d \prod_{j=1; j \neq i}^d p(x_j | x_i) = P^{(0)} \cdot F^{(1)}$$

В этом случае получаем, что помимо моделирования одномерных распределений $p^{\phi_i}(x_i)$, нужно еще моделировать двумерные условные вида $p^{\phi_{i,j}}(x_j | x_i)$. Это ровно то, что и делают алгоритмы, основанные на паренклитике.

Шаг 2: (направленные гиперребра размера 3) предположим, что компоненты независимы в совокупности, если обусловлены на две другие компоненты. Т.е. что (следствие условия) $p(x_i, x_j | x_k, x_l) = p(x_i | x_k, x_l) \cdot p(x_j | x_k, x_l)$. Тогда получим: $p(\mathbf{x}) = p(x_1, \dots, x_d) = p(x_3, \dots, x_d | x_1, x_2) \cdot p(x_1, x_2) = p(x_1) \cdot p(x_2 | x_1) \cdot \prod_{j=1; j \neq 1; j \neq 2}^d p(x_j | x_1, x_2)$.

Симметризуем это выражение. Для этого перемножим по каждой упорядоченной паре (i, j) , выносимых в условие (таких пар $C_d^2 = d(d-1)/2$). Получим:

$$\begin{aligned} p(\mathbf{x})^{(d-1) \cdot d} &= \prod_{i,j=1; i \neq j}^d p(x_i, x_j) \cdot \prod_{k=1; k \neq i; k \neq j}^n p(x_k | x_i, x_j) = \\ &= \prod_{i=1}^d p(x_i) \prod_{j=1; j \neq i}^d p(x_j | x_i) \cdot \prod_{k=1; k \neq i; k \neq j}^d p(x_k | x_i, x_j) = P^{(0)} \cdot F^{(1)} \cdot F^{(2)} \end{aligned}$$

Введем обозначения:

$$\begin{cases} F^{(0)} = \prod_{i=1}^d p(x_i) \\ F^{(1)} = \prod_{i=1}^d \prod_{j=1; j \neq i}^d p(x_j | x_i) \\ F^{(k)} = \prod_{i=1}^d \prod_{I \in \mathcal{I}_k - i}^d p(x_i | x_I) \end{cases}$$

Теперь распишем плотность в общем случае:

$$\begin{aligned} p(\mathbf{x}) &= p(x_1, \dots, x_d) = p(x_1) \cdot p(x_2 | x_1) \cdot p(x_3 | x_1, x_2) \cdot \dots \cdot p(x_k | x_1, \dots, x_{k-1}) \cdot \\ &\quad \cdot [p(x_{k+1} | x_1, \dots, x_k) \cdot p(x_{k+2} | x_1, \dots, x_k) \cdot \dots \cdot p(x_d | x_1, \dots, x_k)] \end{aligned}$$

Итого, получили в произведении префикс (k условных плотностей с увеличивающимся условием) и суффикс $(d - k)$ условных плотностей с одним и тем же условием.

Далее симметризуем: перемножим левую и правую часть по всем $d!$ перестановкам индексов.

Пронумеруем множители с нуля. Для 0 получим:

$$\prod_{(i_1, \dots, i_d) \in \text{PERM}_d} p(x_{i_1}) = (F^{(0)})^{(d-1)! \cdot 0!}$$

Для 1 получим:

$$\prod_{(i_1, \dots, i_d) \in \text{PERM}_d} p(x_{i_2} | x_{i_1}) = (F^{(1)})^{(d-2)! \cdot 1!}$$

Для $k - 1$ получим:

$$\prod_{(i_1, \dots, i_d) \in \text{PERM}_d} p(x_{i_k} | x_{i_1}, \dots, x_{i_{k-1}}) = (F^{(k-1)})^{(d-k)! \cdot (k-1)!}$$

Суффикс же состоит из $d - k$ элементов одинаковых по структуре, поэтому при симметризации они все превратятся в одно и то же произведение. С учетом этого, получим:

$$\begin{aligned} \prod_{(i_1, \dots, i_d) \in \text{PERM}_d} [p(x_{k+1} | x_1, \dots, x_k) \cdot p(x_{k+2} | x_1, \dots, x_k) \cdot \dots \cdot p(x_d | x_1, \dots, x_k)] = \\ = ((F^{(k)})^{(d-k-1)! \cdot (k)!})^{(d-k)} = (F^{(k)})^{(d-k)! \cdot k!} \end{aligned}$$

Итого, получаем разложение плотности в k -ом приближении:

$$p(\mathbf{x})^d = (F^{(0)})^{(d-1)! \cdot 0!} \cdot (F^{(1)})^{(d-2)! \cdot 1!} \cdot \dots \cdot (F^{(k-1)})^{(d-k)! \cdot (k-1)!} \cdot (F^{(k)})^{(d-k)! \cdot k!}$$

Или, логарифмируя:

$$\begin{aligned} \log p(\mathbf{x}) &= \frac{1}{1 \cdot C_d^1} \log F^{(0)} + \frac{1}{2 \cdot C_d^2} \log F^{(1)} + \dots + \frac{1}{k \cdot C_d^k} \log F^{(k-1)} + \frac{1}{C_d^k} \log F^{(k)} = \\ &= \frac{1}{1 \cdot C_d^1} \log F^{(0)} + \frac{1}{2 \cdot C_d^2} \log F^{(1)} + \dots + \frac{1}{k \cdot C_d^k} \log F^{(k-1)} + \frac{\frac{d-k}{k+1}}{C_d^{k+1}} \log F^{(k)} \end{aligned}$$

Где последний член — аппроксимирующий (именно он отвечает за различия между реальной плотностью и приближенной).

Вывод: мы получили набор уточняющих приближений плотности $p(\mathbf{x})$. Каждое приближение задается параметром k — степенью условной независимости компонент $\mathbf{x}$:

1. Чем больше k , тем менее строго предположение о распределении компонентов вектора $\mathbf{x}$ и тем ближе оно к истинному. При $k = 0$ предположение — о совокупной независимости — самое строгое. При $k = d$ общий случай.

2. Плотности менее строгого предположения получаются из более строгого через множитель F^k . Это дает возможность поступенно уточнять вычисление плотности, моделируя условные скалярные распределения на единицу большего порядка. Это оправданно, если параметры старых распределений уже вычислены точно (дисперсия их мала, обучение произошло) и потому есть возможность уточнить прогноз.
3. Количество рассматриваемых плотностей растет экспоненциально:

$$N(k) = A_d^1 + A_d^2 + \dots + A_d^k$$

Как это использовать:

1. В паренклитике производить моделирование высшего порядка (гиперребер). Соответствует шагу 2 и выше. Условие: достаточный объем данных, чтобы добавки $F^{(k)}$ оказали ощутимое влияние.
2. В паренклитике считать ПОЛНОЕ правдоподобие данных (включая по-вершинные, скалярные правдоподобия).
- 3.

2.5 Снижение размерности с помощью synolitic networks. Построение графа

Синолитический метод (Nazarenko et al., 2021) решает задачу бинарной классификации данных и для построения графа использует и контрольную (группа 0, здоровые) и тестовую (группа 1, больные) группы, то есть весь набор данных $\mathcal{D}$

$$\begin{cases} \mathcal{D} = \{(\mathbf{x}_i, y_i)\}_{i=1}^N = \mathcal{D}_0 \sqcup \mathcal{D}_1; \\ \mathcal{D}_0 = \{(\mathbf{x}, y) \in \mathcal{D} : y = 0\}; \\ \mathcal{D}_1 = \{(\mathbf{x}, y) \in \mathcal{D} : y = 1\}; \end{cases}$$

Сначала опишем построение графа по методу SA (synolitic ...), а затем обобщим построение графа.

Для вычисления весов ребер тренируется система разделяющих гиперплоскостей, которые затем преобразуются в бинарные классификаторы $f^{i,j} : \mathbb{R} \times \mathbb{R} \rightarrow [0, 1]$, где $f_{i,j}$

выбирается из моделей радиального SVM с RBF-ядром. То есть (Jakkula, 2006):

$$\left\{ \begin{array}{l} z = \begin{pmatrix} x_i \\ x_j \end{pmatrix} \\ K_\gamma(z, z') = \exp(-\gamma \|z - z'\|^2) : \text{RBF-ядро} \\ f^{i,j}(z) = \sum_{k=1}^n \alpha_k^{i,j} \cdot y^{(k)} \cdot K_\gamma(z^{(k)}, z) + b^{i,j} : \text{разделяющая функция} \\ w^{i,j} = P(y = +1|z) = f^{i,j}(x_i, x_j) = f^{i,j}(z) \approx \frac{1}{1 + \exp(Af(z) + B)} : \text{Platt scaling} \end{array} \right.$$

SVM-задача не решается аналитически, поэтому для ее решения используются алгоритмы численной оптимизации. Где $\alpha_k^{i,j}, b^{i,j}$ — коэффициенты Лагранжа в двойственной к SVM задаче, $y_i \in [-1, 1]$ — метки классов.

Полученная в результате тренировки система бинарных классификаторов $\mathcal{T}^\theta$ используется для преобразования каждого объекта во взвешенный граф, где вес каждого ребра равен вероятности, даваемой соответствующим классификатором, принадлежать к классу +1:

$$\left\{ \begin{array}{l} \mathcal{T}^\theta = \{f_{i,j}^\theta : \mathbb{R} \times \mathbb{R} \rightarrow [0, 1]\} \\ \mathcal{T}^\theta(\mathbf{x}) = A^\mathbf{x} \\ A_{i,j}^\mathbf{x} = w_{i,j}^\mathbf{x} = f_{i,j}^\theta(x_i, x_j) = P^\theta(y = 1|x_i, x_j) \end{array} \right.$$

[ПОЯСНЯЮЩАЯ КАРТИНКА]

Недостатками данного подхода являются 1) отсутствие аналитического решения задачи нахождения весов ребер 2) неинтерпретируемые вероятности, полученные с помощью Platt Scaling из расстояний до разделяющей гиперплоскости. При плохой калибровке интерпретация не будет соответствовать действительности 3) сложности в работе на дискретных признаках (в постановке задачи SVM имеем только непрерывные признаки).

В свою очередь, это затрудняет исследование статистических свойств получаемых графов. Ниже мы дадим обобщение данного подхода.

Интерпретация

1. Вес $w_{i,j}^\mathbf{x} = P(y = 1|x_i, x_j)$ — это оценка вероятности того, что объект $\mathbf{x}$ принадлежит к тесту (болен) при учете только двух признаков (i, j) . То есть данный реберный фиксирует, что у объекта $\mathbf{x}$ в сочетании признаков (i, j) что-то не так (если вес большой) или, наоборот, такое сочетание типично для контроля (здоровья) (если вес близок к нулю).

2. Сила вершины $w^{\mathbf{x}}(i) = \sum_{j=1}^D w_{i,j}^{\mathbf{x}}$ показывает, насколько много нетипичных для контроля (здоровья) связей образует признак i . Чем больше $w^{\mathbf{x}}(i)$, тем больше пар признаков с его участием дают высокую вероятность теста (болезни) и тем более признак i и его значение x_i указывают на болезнь.
3. Для данного объекта $\mathbf{x}$ вершины наибольшей силы — те, которые сильнее указывают на его принадлежность к тесту (болезни). Они и могут формировать аномальную топологию. За счет этого возникает возможность отличать тест и контроль по топологическим признакам.

2.5.1 Обобщение метода synolitic networks построения графа. Вероятностная постановка.

Предположение: $y|x_i, x_j \sim \text{Bern}(p)$.

Будем обучать систему бинарных классификаторов $f_{i,j}^{\theta}(x_i, x_j) = p_{i,j}^{\theta}(y = 1|x_i, x_j)$.

Оптимальные параметры будут подбираться из метода максимального правдоподобия:

$$\begin{cases} \text{Likelihood}(\mathcal{D}|\theta) = \prod_{i,j} \prod_{(\mathbf{x},y) \in \mathcal{D}} [f_{i,j}^{\theta}(x_i, x_j)]^y \cdot [1 - f_{i,j}^{\theta}(x_i, x_j)]^{1-y} \rightarrow \max_{\theta} \\ \log \text{Likelihood}(\mathcal{D}|\theta) = \sum_{i,j} \sum_{(\mathbf{x},y) \in \mathcal{D}} y \cdot \log(f_{i,j}^{\theta}(x_i, x_j)) + (1 - y) \cdot \log(1 - f_{i,j}^{\theta}(x_i, x_j)) \rightarrow \max_{\theta} \end{cases}$$

3 Эксперимент 1: улучшенное генеративное моделирование

Как мы показали теоретически, для любого k мы можем приблизить общую плотность объекта симметричным образом (за счет разложения плотности в ряд).

Покажем, что этот вариант "цепляет" из данных больше информации, чем классический вариант "последовательного" моделирования.

Для этого проведем следующий эксперимент:

Для произвольной пары $(d, k); d > k$, соответствующей размерности признаков И степени созависимости мы сгенерируем случайные гауссовские величины подряд. Каждая следующая зависит от предыдущих k (или меньшего количества для нескольких первых) через случайные линейные коэффициенты. В таком случае результирующий вектор будет нормальным и в произвольной точке мы сможем посчитать плотность.

Далее реализуем семейство моделей, которые также принимают на вход (d, k) , обучающую выборку и учат нормальные условные плотности $p(x_i|x_I)$ с помощью линейной регрессии (учат восстанавливать μ и σ^2).

График сравнения:




Рис. 2: Реальное значение зависимости= 7 (ИСПРАВИТЬ!!! (эксперимент был немного некорректен)). Модели типа ARModel используют авторегрессионное, последовательное моделирование плотности. Суффикс Random — соответствует случайному порядку индексов в такой модели, суффикс Average — усреднение результатов по 10 случайным. Модель Gaussian_Full просто оценивает среднее и ковариационную матрицу по датасету. Модель MyModel — реализует описанный симметризованный алгоритм вычисления плотности. Запущена с порядком созависимости $k = 7$. Train_size=30000, test_size=10000.

Выводы:

1. Наша модель лучше, чем случайный порядок при моделировании плотности (по KL и JS дивергенциям).
2. Наша модель выигрывает по эффективности у всех моделей (в пересчете правдоподобие/количество параметров). Что свидетельствует о ее эффективности.
3. ARModel_Fixed справляется превосходно, т.к. ее фиксированный порядок совпал с порядком генерации.
4. Gaussian_Full справляется превосходно, т.к. размер тренировочных данных был достаточным для вычисления полной матрицы ковариации.




Рис. 3: Реальное значение зависимости=3. Модель MyModel — реализует описанный симметризованный алгоритм вычисления плотности. Запущена с порядком созависимости k . Train_size=30000, test_size=10000.

Теперь сравним наши модели между собой:

Выводы:

1. Чем более сложная наша модель (больше параметр k), тем лучше она приближает распределение.
2. Видим, что и после $k = 3$ есть улучшения, хотя реальное значение параметра зависимости = 3. Это возможно потому, что данные использовались зашумленные.
3. Оптимальный параметр k можно увидеть из графика loglik/param — на $k = 2/3$ эффективность перестает меняться.

Теперь изучим, как наша модель ведет себя при увеличении размерности параметров: [ПРОВЕСТИ ЭКСПЕРИМЕНТ ЗАНОВО, Т.К. ВСЕ УХОДИТ В РАЗНОС (ЭКСПОНЕНЦИАЛЬНЫЙ)]

Выводы:

1. При росте размерности дисперсия оценки дивергенций возрастает значительно.
2. Оптимальность модели возрастает (моделируем более сложную зависимость простой).




Рис. 4: Реальное значение зависимости=2. Модель MyModel — реализует описанный симметризованный алгоритм вычисления плотности с параметром ($k = 2$). Train_size=30000, test_size=10000.

Теперь изучим, как зависит качество моделирования от шума в данных и от размера обучающей выборки:

$$p(\mathbf{x})^{d \cdot (d-1) \cdot \dots \cdot (d-k+1)} = P^{(0)} \cdot F^{(1)} \cdot F^{(2)} \cdot \dots \cdot F^{(k)}$$

Этот метод мы можем сравнить с последовательным разложением в ряд:

$$p(\mathbf{x}) =$$

Покажем экспериментально, что такой подход дает лучший результат.

Возможны 2 варианта проведения эксперимента:

- Вариант 1: ближе распределение.

4 Обработка изображений с помощью parenclitic и synolitic networks

5 Обработка временных рядов с помощью parenclitic и synolitic networks

6 О генеративном и дискриминативном моделировании

Здесь мы проведем обзор литературы и сравним, какими преимуществами и недостатками обладают генеративное и дискриминативное моделирование. Нужно, чтобы показать мат. вклад паренклитики и синолитики.

В статье (Ng and Jordan, 2001) авторы показали, что использование генеративных классификаторов (основанных на оценке плотности, как в подходе parenclitic, например, Naive Bayes) и дискриминативных (учат вероятности классов напрямую, как в подходе synolitic, например, Logistic Regression) зависит от параметров выборки:

1. Для **малых выборок** генеративные модели работают лучше (быстрее сходятся):

$$Error_{NB}(n) = \Theta\left(\frac{1}{\sqrt{n}}\right)$$

2. Для **больших выборок** у дискриминативных моделей ниже асимптотическая ошибка:

$$Error_{LR}(n) = \Theta\left(\frac{1}{n}\right)$$

В работе (Zheng et al., 2023) авторы показали, что генеративное моделирование требует меньшего числа данных для достижения оптимальной классификации, однако количество параметров в обычных генеративных моделях растет квадратично с размерностью признаков (нужна оценка ковариационной матрицы), что делает вычисления долгими:

1. Naive Bayes требует $O(\log d)$ данных (где d — размерность признаков)
2. Logistic Regression требует $O(d)$ данных (где d — размерность признаков)

Список литературы

- Картографирование плавучих льдов для навигации в полярных регионах.
<https://arcreview.esri-cis.ru/2015/10/08/sea-ice-and-iceberg-maps>.
- Lada A Adamic, Rajan M Lukose, Amit R Puniyani, and Bernardo A Huberman. Search in power-law networks. *Physical review E*, 64(4):046135, 2001.
- Lluís Castrejon, Nicolas Ballas, and Aaron Courville. Improved conditional vrnnns for video prediction. In *Proceedings of the IEEE/CVF international conference on computer vision*, pages 7608–7617, 2019.
- Junyoung Chung, Kyle Kastner, Laurent Dinh, Kratarth Goel, Aaron C Courville, and Yoshua Bengio. A recurrent latent variable model for sequential data. *Advances in neural information processing systems*, 28, 2015.
- John P Cunningham and Byron M Yu. Dimensionality reduction for large-scale neural recordings. *Nature neuroscience*, 17(11):1500–1509, 2014.
- Vadim Demichev, Pinkus Tober-Lau, Tatiana Nazarenko, Oliver Lemke, Simran Kaur Aulakh, Harry J Whitwell, Annika Röhl, Anja Freiwald, Mirja Mittermaier, Lukasz Szyrwił, et al. A proteomic survival predictor for covid-19 patients in intensive care. *PLOS Digital Health*, 1(1):e0000007, 2022.
- Xin Dong, Shangyu Chen, and Sinno Pan. Learning to prune deep neural networks via layer-wise optimal brain surgeon. *Advances in Neural Information Processing Systems*, 30, 2017.
- Matthew F Glasser, Timothy S Coalson, Emma C Robinson, Carl D Hacker, John Harwell, Essa Yacoub, Kamil Ugurbil, Jesper Andersson, Christian F Beckmann, Mark Jenkinson, et al. A multi-modal parcellation of human cerebral cortex. *Nature*, 536(7615):171–178, 2016.
- Timofey Grigoryev, Polina Verezemskaya, Mikhail Krinitskiy, Nikita Anikin, Alexander Gavrikov, Ilya Trofimov, Nikita Balabin, Aleksei Shpilman, Andrei Eremchenko, Sergey Gulev, et al. Data-driven short-term daily operational sea ice regional forecasting. *Remote Sensing*, 14(22):5837, 2022.

- Babak Hassibi, David G Stork, and Gregory J Wolff. Optimal brain surgeon and general network pruning. In *IEEE international conference on neural networks*, pages 293–299. IEEE, 1993.
- Tobias Höppe, Arash Mehrjou, Stefan Bauer, Didrik Nielsen, and Andrea Dittadi. Diffusion models for video prediction and infilling. *arXiv preprint arXiv:2206.07696*, 2022.
- RV Isachenko and VV Strijov. Quadratic programming feature selection for multicorrelated signal decoding with partial least squares. *Expert Systems with Applications*, 207:117967, 2022.
- Vikramaditya Jakkula. Tutorial on support vector machine (svm). *School of EECS, Washington State University*, 37(2.5):3, 2006.
- Yan Ji, Bing Gong, Michael Langguth, Amirpasha Mozaffari, and Xiefei Zhi. Clgan: A gan-based video prediction model for precipitation nowcasting. *EGUsphere*, pages 1–23, 2022.
- Weikuan Jia, Meili Sun, Jian Lian, and Sujuan Hou. Feature dimensionality reduction: a review. *Complex & Intelligent Systems*, 8(3):2663–2693, 2022.
- M Krivonosov, T Nazarenko, MG Bacalini, C Franceschi, A Zaikin, and M Ivanchenko. Dna methylation changes with age as a complex system: A parenclitic network approach to a family-based cohort of patients with down syndrome. *bioRxiv*, pages 2020–03, 2020.
- Mikhail Krivonosov, Tatiana Nazarenko, Maria Giulia Bacalini, Maria Vedunova, Claudio Franceschi, Alexey Zaikin, and Mikhail Ivanchenko. Age-related trajectories of dna methylation network markers: A parenclitic network approach to a family-based cohort of patients with down syndrome. *Chaos, Solitons & Fractals*, 165:112863, 2022.
- Mikhail Krivonosov, Tatiana Nazarenko, Vadim Ushakov, Daniil Vlasenko, Denis Zakharov, Shangbin Chen, Oleg Blyus, and Alexey Zaikin. Analysis of multidimensional clinical and physiological data with synolitical graph neural networks. *Technologies*, 13(1), 2024.
- Tatiana Nazarenko, Harry J Whitwell, Oleg Blyuss, and Alexey Zaikin. Parenclitic and synolytic networks revisited. *Frontiers in genetics*, 12:733783, 2021.
- Andrew Ng and Michael Jordan. On discriminative vs. generative classifiers: A comparison of logistic regression and naive bayes. *Advances in neural information processing systems*, 14, 2001.

- Cem Örnek and Elif Vural. Nonlinear supervised dimensionality reduction via smooth regular embeddings. *Pattern Recognition*, 87:55–66, 2019.
- Stein Sandven, Gunnar Spreen, Georg Heygster, Fanny Girard-Ardhuin, Sinéad Farrell, Wolfgang Dierking, and Richard Allard. Sea ice remote sensing—recent developments in methods and climate data sets. *Surveys in Geophysics*, 44:1–37, 04 2023. doi: 10.1007/s10712-023-09781-0.
- Younggyo Seo, Kimin Lee, Fangchen Liu, Stephen James, and Pieter Abbeel. Harp: Autoregressive latent video prediction with high-fidelity image generator. In *2022 IEEE International Conference on Image Processing (ICIP)*, pages 3943–3947. IEEE, 2022.
- Xingjian Shi, Zhourong Chen, Hao Wang, Dit-Yan Yeung, Wai-Kin Wong, and Wang-chun Woo. Convolutional lstm network: A machine learning approach for precipitation nowcasting. *Advances in neural information processing systems*, 28, 2015.
- Nikita Sushentsev, Leonardo Rundo, Oleg Blyuss, Tatiana Nazarenko, Aleksandr Suvorov, Vincent J Gnanapragasam, Evis Sala, and Tristan Barrett. Comparative performance of mri-derived precise scores and delta-radiomics models for the prediction of prostate cancer progression in patients on active surveillance. *European radiology*, 32(1):680–689, 2022.
- Laurens Van Der Maaten, Eric O Postma, H Jaap Van Den Herik, et al. Dimensionality reduction: A comparative review. *Journal of machine learning research*, 10(66-71):13, 2009.
- Daniil Vlasenko, Alexey Zaikin, and Denis Zakharov. Ensemble methods for representation of fmri, eeg/meg data in graph form for classification of brain states. In *2024 8th Scientific School Dynamics of Complex Networks and their Applications (DCNA)*, pages 258–261. IEEE, 2024.
- Vikram Voleti, Alexia Jolicoeur-Martineau, and Chris Pal. Mcvd-masked conditional video diffusion for prediction, generation, and interpolation. *Advances in Neural Information Processing Systems*, 35:23371–23385, 2022.
- Ruihan Yang, Prakhar Srivastava, and Stephan Mandt. Diffusion probabilistic modeling for video generation. *Entropy*, 25(10):1469, 2023.
- Muxuan Yuan and Qun Dai. A novel deep pixel restoration video prediction algorithm integrating attention mechanism. *Applied Intelligence*, pages 1–19, 2022.

- M Zanin and S Boccaletti. Complex networks analysis of obstructive nephropathy data. *Chaos: An Interdisciplinary Journal of Nonlinear Science*, 21(3), 2011.
- Anru R Zhang and Yuchen Zhou. On the non-asymptotic and sharp lower tail bounds of random variables. *Stat*, 9(1):e314, 2020.
- Chenyu Zheng, Guoqiang Wu, Fan Bao, Yue Cao, Chongxuan Li, and Jun Zhu. Revisiting discriminative vs. generative classifiers: Theory and implications. In *International conference on machine learning*, pages 42420–42477. PMLR, 2023.
- Андрей Валериевич Грабовой, Олег Юрьевич Бахтеев, and Вадим Викторович Стрижов. Определение релевантности параметров нейросети. *Информатика и её применения*, 13(2):62–70, 2019.
- Андрей Валериевич Грабовой, Олег Юрьевич Бахтеев, and Вадим Викторович Стрижов. Введение отношения порядка на множестве параметров аппроксимирующих моделей. *Информатика и её применения*, 14(2):58–65, 2020.