

Анализ данных большой размерности при малом размере выборки

Насыров Р.Р., Зайцев А.А.

МФТИ

20 декабря 2025 г.

Разработан теоретический фундамент паренклитических сетей:

- 1 Найдены распределения весов вершин для случая L1- и L2-расстояний.
- 2 Найдено теоретическое обоснование полезности признаков, полученных эмпирическим путем авторами прошлых статей
- 3 Доказано, что распределения весов вершин не подчиняется power-law закону
- 4 Доказана теорема о комбинаторном разложении многомерной плотности. На ее основе создан алгоритм многомерной оценки плотности, превосходящий стандартные подходы.

Цель исследования: предложить интерпретируемый способ решения задачи классификации в условиях недостатка данных и (или) наличия пропусков в них.

Задача: бинарная классификация многомерных данных.

Специфика данных: размерность данных достаточно большая по сравнению с их количеством: $D > N$, что ограничивает применимость стандартных моделей, т.к. может привести к их переобучению.

Введение

Паренклитические графы в бинарной классификации

Данные разделены на две части: контроль (группа 0, здоровые) и тест (группа 1, больные).

$$\begin{cases} \mathcal{D} = \{(x_i, y_i)\}_{i=1}^N = \mathcal{D}_0 \sqcup \mathcal{D}_1; \\ \mathcal{D}_0 = \{(x, y) \in \mathcal{D} : y = 0\}; \\ \mathcal{D}_1 = \{(x, y) \in \mathcal{D} : y = 1\}; \end{cases}$$

Далее на контрольной группе обучается система линейных регрессий, предсказывающая по одному признаку объекта другой:

$$\begin{cases} \mathcal{T}_{\mathcal{D}_0}^\theta = \{f_{i,j}^\theta : \mathbb{R}^D \rightarrow \mathbb{R}^D; f_{i,j}^\theta(x_i) = \alpha_{i,j}^\theta + \beta_{i,j}^\theta \cdot x_i\} \\ \mathcal{L}(\theta) = \mathbb{E}_{x \in \mathcal{D}_0} \sum_{i,j} |f_{i,j}^\theta(x_i) - x_j| \rightarrow \min_{\theta} \\ f_{i,j}^\theta(x) = \theta_b^{i,j} + \theta_a^{i,j} \cdot x \text{ (линейная регрессия)} \\ \mathcal{L}(\theta) = \sum_{x \in \mathcal{D}_0} \sum_{i,j} \left| x_j - \left(\theta_b^{i,j} + \theta_a^{i,j} \cdot x_i \right) \right| \rightarrow \min_{\theta} \end{cases} \quad (1)$$

Введение

Паренклитические графы в бинарной классификации

Система линейный регрессий $\mathcal{T}_{\mathcal{D}_0}^\theta$ преобразует объект x в матрицу смежности графа $A^x \in \mathbb{R}^D \times \mathbb{R}^D$:

$$\begin{cases} \mathcal{T}_{\mathcal{D}_0}^\theta(x) = A^x \\ A_{i,j}^x = w_{i,j}^x = |f_{i,j}^\theta(x_i) - x_j| \end{cases}$$

Далее:

- 1 Извлечение *топологических признаков* вершин и ребер
- 2 Классификация по извлеченным признакам

Ключевое предположение: топология графов с $y = 0$ и $y = 1$ отличаются достаточно сильно.

Введение

Паренклитические графы в бинарной классификации




Рис.: Пример создания
паренклитического графа




Рис.: Пример паренклитических
графов для разных классов
(вертикаль) и разных данных
(горизонталь).

Математика паренклитики. Эквивалентность

Теорема: Обучение регрессоров $f_{i,j}^\theta \iff$ обучению $p^\phi(x_j|x_i, y=0)$ в семействе $\phi \in \Phi = \{\mathcal{N}(\phi_a^{i,j}x_i + \phi_b^{i,j}, (\phi_\sigma^{i,j})^2)\}$ с помощью максимизации логарифма правдоподобия.

Логарифм правдоподобия:

$$\log L = \sum_{x \in \mathcal{D}_0} \sum_{i,j} \log p^{\phi^{i,j}}(x_j|x_i, y=0) \rightarrow \max_{\phi \in \tilde{\Phi}}$$

Введение

Математика паренклитики. Доказательство эквивалентности. LDPA

Предположим, что остатки линейной регрессии распределены по Лапласу:

$$\begin{cases} x_j = ax_i + b + \xi \\ \xi \sim \text{Lapl}(0, 1) \\ p(\xi) = \frac{1}{2} e^{-|\xi|} \end{cases}$$

Тогда задача максимального правдоподобия для каждой пары (i, j) примет вид:

$$-\log L_{i,j} = n \cdot \log(2) + \frac{1}{2} \sum_{x \in \mathcal{D}_0} |x_j - (a_{i,j}x_i + b_{i,j})| \rightarrow \min_{a_{i,j}, b_{i,j}}$$

Эквивалентность простому обучению регрессоров.

Математика паренклитики. Гауссовский подход

Распределение Лапласа не дает возможности аналитически вычислить решение задачи максимального правдоподобия.

Предположение нормальности остатков линейной регрессии:

$$\begin{cases} x_j = ax_i + b + \xi \\ \xi \sim \mathcal{N}(0, 1) \\ p(\xi) = \frac{1}{2\pi} e^{-\frac{|\xi|^2}{2}} \end{cases} \text{ т.к. параметр размерности } 1$$

Тогда задача максимального правдоподобия для каждой пары (i, j) примет вид:

$$-\log L_{i,j} = n \cdot \log(2\pi) + \frac{1}{2} \sum_{x \in \mathcal{D}_0} (x_j - (a_{i,j}x_i + b_{i,j}))^2 \rightarrow \min_{a_{i,j}, b_{i,j}}$$

А это задача МНК, которая имеет аналитическое решение!

Математика паренклитики. Полезность признаков

Веса ребер — вероятностные:

$$\begin{cases} x \in \mathcal{D}_0 \rightarrow A_{i,j}^x = w_{i,j}^x = p^{\phi^*}(x_j | x_i, y = 0) \\ x \in \mathcal{D}_1 \rightarrow A_{i,j}^x = w_{i,j}^x = p^{\phi^*}(x_j | x_i, y = 0) \end{cases}$$

Правдоподобие вершины:

$$\begin{cases} \log(\text{Likelihood}_{out}(A^x, i)) = \sum_{j=1}^n p^{\phi^*}(x_j | x_i, y = 0) \\ \log(\text{Likelihood}_{in}(A^x, i)) = \sum_{j=1}^n p^{\phi^*}(x_i | x_j, y = 0) \end{cases}$$

Правдоподобие всего графа:

$$\log \text{Likelihood}(A^x) = \sum_{i,j=1}^n \log \left(p^{\phi^*}(x_j | x_i, y = 0) \right)$$

Вывод: *выжный признак вес вершины* — это ее правдоподобие.

Математика паренклитики. Распределение весов вершин и ребер

Предположение: Генеративная модель задана неявно условиями:

$$\begin{cases} p(x_j|x_i) \sim \mathcal{N}(a_{i,j}x_i + b_{i,j}; \sigma^2) \\ p(x_i, x_j|x_k) = p(x_i|x_k) \cdot p(x_j|x_k); \end{cases}$$

Задача линейной регрессии для ребра $x_i \rightarrow x_j$ запишется в виде:

$$\begin{cases} Z = X \cdot \theta + \xi \\ \theta = \begin{pmatrix} a & b \end{pmatrix} \\ \xi \sim \mathcal{N}(0, \sigma^2 I) \end{cases} \quad Z = \begin{pmatrix} x_j^1 \\ x_j^2 \\ \dots \\ x_j^n \end{pmatrix} X = \begin{pmatrix} x_i^1 & 1 \\ x_i^2 & 1 \\ \dots & \dots \\ x_i^n & 1 \end{pmatrix}$$

Решение задачи — из теории линейной регрессии:

$$\begin{cases} \hat{\theta} = (X^T X)^{-1} X^T Z; \quad H = X(X^T X)^{-1} X^T \\ w_{i,j}^k = (e_{i,j}^k)^2 = |x_j^k - x_i^k \cdot \hat{a}_{i,j} - \hat{b}_{i,j}| \sim \sigma^2 \cdot (1 - h_{k,k}) \cdot \chi_1^2 \end{cases}$$

Распределение степеней вершин (предполагаем независимость):

$$s^k(i) = \sum (e_{i,j}^k)^2 \sim \sum \sigma^2 \cdot (1 - h_{k,k}) \cdot \chi_1^2 \sim \sigma^2 (1 - h_{k,k}) \chi_{d-1}^2$$

Комбинаторное разложение полной вероятности

Задача: научиться моделировать плотность $p(x) = p(x_1, \dots, x_d)$ на малом наборе данных.

Пусть $x = (x_1, \dots, x_d) \in \mathbb{R}^d$.

- $PERM_d$: множество перестановок индексов $(i_1, \dots, i_d)$, размер $d!$.
- $A_d^m = \frac{d!}{(d-m)!}$: число упорядоченных выборок длины m .
- $C_d^m = \binom{d}{m}$.

Введём семейство произведений условных плотностей:

$$F^{(0)} = \prod_{i=1}^d p(x_i); \quad F^{(1)} = \prod_{i=1}^d \prod_{\substack{j=1 \\ j \neq i}}^d p(x_j \mid x_i); \quad F^{(r)} = \prod_{i=1}^d \prod_{l \in \mathcal{I}_r(i)} p(x_i \mid x_l)$$

где $\mathcal{I}_r(i)$ — множество всех упорядоченных r -кортежей индексов, не содержащих i .

Комбинаторное разложение полной вероятности

Серия обобщающих предположений о созависимости признаков $(x_1, \dots, x_d)$:

- ① (0) Независимы в совокупности
- ② (1) Независимы в совокупности при обуславливании на 1 признак
- ③ (k) Независимы в совокупности при обуславливании на k признаков
- ④ (d-1) Отсутствие предположений

Теорема: В предположении порядка k (признаки независимы в совокупности при условии мощности k):

$$\log p(x) = \frac{1}{1 \cdot C_d^1} \log F^{(0)} + \frac{1}{2 \cdot C_d^2} \log F^{(1)} + \dots + \frac{1}{k \cdot C_d^k} \log F^{(k-1)} + \frac{1}{C_d^k} \log F^{(k)}$$

Вывод: получили разложение полной плотности на набор одномерных условных симметризованных плотностей.

Результаты экспериментов

Данные:

$$p(x_i | \text{prefix}) = N(\mu_i + w_i^T * \text{prefix}, \sigma_i^2)$$




Рис.: $k = 7$. Правый столбец — симметричная модель.

Выводы:

- 1 Симметричная модель лучше, чем случайный порядок при моделировании плотности.
- 2 Симметричная модель — max эффективности по параметрам.

Результаты экспериментов




Рис.: $k = 7$

Выводы:

- 1 Большая модель (k) — лучшее приближение.
- 2 TradeOff сложность/качество достигается при $k = 2, 3$.
Зависимости сложнее нет смысла учитывать.

Результаты экспериментов

Данные: $x_i \sim \mathcal{N}(0, \sigma^2)$; $x_i \leq k = 3$ предыдущих.




Рис.: $k = 3$.

Выводы:

- 1 $k = 1$ лучше на размерах выборок до $N \leq 75$. Это и есть случай паренклитических графов!
- 2 Модели выходят на плато качества.

Выводы

- 1 Паренклитические графы — результат генеративного моделирования плотности. Их признаки имеют прямую вероятностную интерпретацию.
- 2 Симметричное моделирование многомерной плотности делает лучше "выцепляет" информацию из данных, чем классические схемы, хотя и экспоненциально сложно по числу признаков.
- 3 Паренклитические графы — это (1)-приближение плотности. Оно работает лучше других на малых размерах выборок (< 75 в экспериментальном случае).
- 4 (k) приближения соответствуют k -однородным гиперграфам. Что делает моделирование сложнее и точнее, но оправдано только на больших данных.

Следующие шаги

- Contrastive parenclitic algorithm (уже сделан, экспериментов не проведено)
- Моделирование:
 - ① Spatio-Temporal graphs
 - ② Graphs on image
 - ③ Graphs on multy-domain data
- Разработка алгоритма байесовской спарсификации.
- Эксперименты на реальных данных.
- Обобщение теории на синолитические графы.

Литература

- 1 Tatiana Nazarenko, Harry J. Whitwell, Oleg Blyuss, Alexey Zaikin. “Parenclitic and synolytic networks revisited”. In: *Frontiers in Genetics* 12 (2021), Article 733783.
- 2 Andrew Y. Ng, Michael I. Jordan. “On discriminative vs. generative classifiers: A comparison of logistic regression and naive Bayes”. In: *Advances in Neural Information Processing Systems* 14 (2001).
- 3 Weikuan Jia, Meili Sun, Jian Lian, Sujuan Hou. “Feature dimensionality reduction: a review”. In: *Complex & Intelligent Systems* 8.3 (2022), pp. 2663–2693.
- 4 Mikhail Krivososov, Tatiana Nazarenko, Vadim Ushakov, Daniil Vlasenko, Denis Zakharov, Shangbin Chen, Oleg Blyuss, Alexey Zaikin. “Analysis of Multidimensional Clinical and Physiological Data with Synolitical Graph Neural Networks”. In: *Technologies* 13.1 (2024).
- 5 Mikhail Krivososov, Tatiana Nazarenko, Maria Giulia Bacalini, Maria Vedunova, Claudio Franceschi, Alexey Zaikin, Mikhail Ivanchenko. “A parenclitic network approach to a family-based cohort of patients with Down Syndrome”.