

Анализ данных большой размерности при малом размере выборки

Насыров Р. Р.

Научный руководитель:
к.ф.-м.н. Заикин А. А.

МФТИ


6 июня 2026 г.

Предложено: алгоритм бинарной классификации табличных данных.

Обеспечивающий: большую точность классификации (на мед. датасетах), чем синоптическая графовая нейросеть SGNN с архитектурой GATv2 в foundation-режиме на 15 UCI-датасетах [SGNN, *Technologies* 2026, 14, 84], а также большую точность на синтетических данных с контролируемой степенью зависимости.

Отличающийся: наличием теоретического обоснования точности восстановления плотности объектов.

Схема метода и сравнение с байзлайнами



Введение

Паренклитические графы в бинарной классификации




Рис.: Пример создания
паренклитического графа




Рис.: Пример паренклитических
графов для разных классов
(вертикаль) и разных данных
(горизонталь).

Определения и обозначения

Паренклитика разлагает плотность $p(x)$, синологитика — условную модель $p(y | x)$; обе — по порядкам условия k .

Объекты и индексы

$x = (x_1, \dots, x_d) \in \mathbb{R}^d$ — объект, $y \in \{0, 1\}$ — метка

$[d] = \{1, \dots, d\}$; $I, S, T \subseteq [d]$ — подмножества

$x_I = (x_i)_{i \in I}$ — подвектор, $x_{-S} = (x_j)_{j \notin S}$
 $|I|$ — мощность; N — размер выборки, d — размерность

Распределения

$p(x)$ — плотность объекта

$p(y | x)$ — условная плотность

$p(x_i | x_I)$ — условная плотность признака

$C_d^r = \binom{d}{r}$ — биномиальный коэффициент

Ключевые величины

k — порядок условия (степень зависимости)

TC — полная корреляция, $TC(\cdot | \cdot)$ — условная

$\delta_k = \max_{|S|=k} TC(x_{-S} | x_S)$ — ошибка k -приближения

$\approx_k$ — приближение k -го порядка; D_{KL} — дивергенция КЛ

Предпосылки и ограничения

бинарная классификация, признаки

числовые

$p(x) > 0, p(x_i | x_I) > 0$ почти всюду

Теоремы о разложении по порядкам условия

Теорема 1 (паренклитическое разложение).

Если $p(x)$ — плотность на $\mathbb{R}^d$, то $\forall k \leq d-1$

$$\log p(x) = \sum_{r=0}^{k-1} \frac{\log F^{(r)}}{(r+1) C_d^{r+1}} + \frac{(d-k) \log F^{(k)}}{(k+1) C_d^{k+1}},$$

$$F^{(r)} = \prod_{i=1}^d \prod_{|I|=r, i \notin I} p(x_i | x_I).$$

Теорема 2 (синолитическое разложение).

Если $p(y | x)$ — условная модель, то $\forall k \leq d$

$$\log p(y | x) \approx_k \sum_{t=0}^k c^{(k)}(t, d) \sum_{T \subseteq [d], |T|=t} \log p(y | x_T),$$

$$c^{(k)}(t, d) = \sum_{s=0}^{k-t} (-1)^s C_{d-t}^s.$$

Частные случаи:

$k=0$ — независимость

$k=1$ — классич. паренклитика

$k \geq 2$ — гиперрѐбра

Симметризация по $d!$

перестановкам $\Rightarrow$ точные
биномиальные коэфф.

Частные случаи:

$k=1$ — наивный Байес

$k=2$ — классич. синолитика

$k \geq 3$ — гиперрѐбра

$c^{(k)}(t, d) = 0$ при $t > k$.

Строгая k -независимость вырождена

Определение (классическая паренклитическая k -независимость)

Случайный вектор X с плотностью $p > 0$ называется *строго k -независимым*, если для любого $S \subseteq [d]$, $|S| = k$, компоненты $\{X_j\}_{j \notin S}$ условно независимы при X_S :

$$p(x_{-S} \mid x_S) = \prod_{j \notin S} p(x_j \mid x_S).$$

Теорема ТЗ (вырожденность)

Если X строго k -независим при некотором $0 < k < d - 1$, то компоненты $X_1, \dots, X_d$ независимы в совокупности:

$$p(x) = \prod_{i=1}^d p(x_i).$$

Следствие. Строгое определение не различает порядки $k \in \{1, \dots, d - 2\}$ — его нужно ослабить.

Ослабление: (ε, k) -независимость через δ_k

Определение $((\varepsilon, k)$ -независимость)

Случайный вектор X называется (ε, k) -независимым, если $\delta_k(X) \leq \varepsilon$, где

$$\delta_k(X) := \max_{|S|=k} D_{\text{KL}}\left(p(x_{-S} \mid x_S) \parallel \prod_{j \notin S} p(x_j \mid x_S)\right).$$

Это максимальная условная полная корреляция остатка x_{-S} при x_S .

Теорема Т4 (свойства δ_k)


- 1 **Монотонность:** $\delta_{k+1} \leq \delta_k$ — больше условий, меньше остаточной зависимости.
- 2 **k -разложимость:** k -усечённая факторизация q_k (Теорема 1) приближает p : $D_{\text{KL}}(p \parallel q_k) \leq \delta_k$.
- 3 **Граничные случаи:** $\delta_0 = 0 \Leftrightarrow$ полная независимость; $\delta_{d-1} \equiv 0$.
- 4 **Невырожденность:** для каждого $k \in \{1, \dots, d-2\}$ существует распределение p с $0 < \delta_k < \delta_{k-1}$.

Демонстрация: δ_k на равнокоррелированной гауссовой модели

Модель: $X \sim \mathcal{N}(0, \Sigma)$, $\Sigma_{ii} = 1$, $\Sigma_{ij} = \rho$ при $i \neq j$

Точная формула ($r = \frac{\rho}{1+k\rho}$):



$$\delta_k(d, \rho) = -\frac{1}{2} \left[(d-k-1) \log(1-r) + \log(1+(d-k-1)r) \right].$$



Правило выбора k при известном ε

Идея. По заданному бюджету ε ищем минимальный порядок, который укладывается:

$$k_{\min}(\varepsilon, d, \rho) = \min\{k \in \{0, \dots, d-1\} : \delta_k(d, \rho) \leq \varepsilon\}.$$



- (а) тепловая карта $\delta_k(\rho, k)$ при $d = 20$ с уровнями ε (чёрные пунктиры) и долями снятия 50 % / 90 % / 99 % (белые сплошные).
- (б) $k_{\min}/d$ как функция ε при разных ρ и d .

Теорема Т5 (о слепоте): датасеты Parity- k и MixedParity

Теорема Т5 (о слепоте)

Если $X_j \sim U(-1, 1)$ i.i.d, индексы разбиты на блоки B_i длины k , а метка $Y = \text{sign}(\sum_i \text{sign}(\prod_{j \in B_i} X_j))$ (схема Parity- k), то для любого $I \subset [d]$ с $|I| = m < k$

$$P(Y = +1 | x_I) = \frac{1}{2},$$


т.е. любой набор из менее чем k признаков неинформативен.

Parity- k : AUC в зависимости от тестового k (порядка модели)
тризнаков во всех экспериментах | Серые столбцы — слепые порядки (тест. $k < k$ датасета) | Цветные — информативный по



Parity- k : слепота при $m < k$

Mixed Parity: AUC по тестовому k (порядку модели)
Серый — слеп | Полупрозрачный — видит k_1 компоненту | Темный — видит обе компоненты



MixedParity: ступеньки при $m = k_1, k_2$

Результаты экспериментов

Данные: $x_i \sim \mathcal{N}(0, \sigma^2)$; $x_i \leq k = 3$ предыдущих.




Рис.: $k = 3$.

Выводы:


- 1 $k = 1$ лучше на размерах выборок до $N \leq 75$. Это и есть случай паренклитических графов!
- 2 Модели выходят на плато качества.

Устойчивость моделей к деградации обучающих данных

Сетап: сферы $d = 10$, 5 классификаторов на raw vs MyModel-фичах ($k = 2$), 5 seed.


- **Шум** (доля повреждённых меток): MyModel сохраняет AUC дольше, чем raw.
- **Размер выборки n_{train}** : MyModel доминирует на малых n (где паренклитика теоретически оптимальна).

Устойчивость моделей к шуму в обучающих данных ($d = 7$, $k_{\text{true}} = 3$, $n_{\text{train}} = 5000$)



AUC vs доля шума в метках


Устойчивость моделей к уменьшению объёма данных ($d = 7$, $k_{\text{true}} = 3$)



AUC vs n_{train}

Синтетические датасеты


Synthetic benchmarks: наши методы vs SGNN



Реальные данные: лучший AUC и оптимальное k по парам моделей

UCI-датасеты

Synolitic + LogReg vs SGNN GATv2 (UCI/мед-датасеты, ROC-AUC, 5-fold CV)



Тезисы, выносимые на защиту

Доказаны теоремы, обосновывающие паренклитические и синолитические сети:

- 1 Разложения по порядкам условия — плотности $\log p(x)$ (T1) и условной модели $\log p(y | x)$ через обращение Мёбиуса (T2); тем самым теоретически обоснованы эмпирически полезные паренклитические признаки прошлых работ.
- 2 Вырожденность строгой k -независимости: при $0 < k < d - 1$ она влечёт полную независимость (T3) — классическое определение тривиально.
- 3 Невырожденное (ε, k) -ослабление через δ_k (условную total correlation) с доказанными свойствами: монотонность, k -разложимость, невырожденность (T4).
- 4 Замкнутая формула $\delta_k(d, \rho)$ для гауссовой равнокоррелированной модели; определяющим является относительное покрытие k/d , отсюда правило выбора k по бюджету ε .

Практические результаты:

- 1 Синтетические датасеты Parity- k и MixedParity с доказанной «слепотой» (T5) — диагностика порядка зависимости, улавливаемого моделью.
- 2 Реализованы паренклитические и синолитические модели с управляемым порядком k .
- 3 Очерчены границы применимости: в режиме $d > N$ на данных с парной структурой учёт зависимостей выигрывает, на данных без неё raw-признаки

Литература

- ① Tatiana Nazarenko, Harry J. Whitwell, Oleg Blyuss, Alexey Zaikin. “Parenclitic and synolytic networks revisited”. In: *Frontiers in Genetics* 12 (2021), Article 733783.
- ② Andrew Y. Ng, Michael I. Jordan. “On discriminative vs. generative classifiers: A comparison of logistic regression and naive Bayes”. In: *Advances in Neural Information Processing Systems* 14 (2001).
- ③ Weikuan Jia, Meili Sun, Jian Lian, Sujuan Hou. “Feature dimensionality reduction: a review”. In: *Complex & Intelligent Systems* 8.3 (2022), pp. 2663–2693.
- ④ Mikhail Krivososov, Tatiana Nazarenko, Vadim Ushakov, Daniil Vlasenko, Denis Zakharov, Shangbin Chen, Oleg Blyuss, Alexey Zaikin. “Analysis of Multidimensional Clinical and Physiological Data with Synolitical Graph Neural Networks”. In: *Technologies* 13.1 (2024).
- ⑤ Mikhail Krivososov, Tatiana Nazarenko, Maria Giulia Bacalini, Maria Vedunova, Claudio Franceschi, Alexey Zaikin, Mikhail Ivanchenko. “A parenclitic network approach to a family-based cohort of patients with Down Syndrome”.