

Анализ данных большой размерности при малом размере выборки

Насыров Р. Р.

Научный руководитель:
к.ф.-м.н. Заикин А. А.

МФТИ

17 июня 2026 г.

Предложено: алгоритм бинарной классификации табличных данных *SynoliticGraphClassifier*.

Обеспечивающий: большую точность классификации (на мед. датасетах), чем синолитическая графовая нейросеть SGNN с архитектурой GATv2 в foundation-режиме на 11 UCI-датасетах [SGNN, *Technologies* 2026, 14, 84], а также большую точность на синтетических данных с контролируемой степенью зависимости.

Отличающийся: наличием теоретического обоснования точности восстановления плотности объектов.

Постановка задачи

Решается задача **бинарной классификации** в режиме $d > N$ (признаков больше, чем объектов): классические модели переобучаются, поэтому переходим к графовому представлению.

Данные. $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^N$, $x \in \mathbb{R}^d$, $y \in \{0, 1\}$, признаки числовые.

Критерий — максимум лог-правдоподобия:

$$\mathcal{L}(\theta) = \sum_{i=1}^N [y_i \log p(y=1 \mid x_i, \theta) + (1-y_i) \log (1-p(y=1 \mid x_i, \theta))] \rightarrow \max_{\theta}.$$

Снижение размерности через граф: $x \rightarrow$ граф объекта $\rightarrow$ признаки $\rightarrow$ классификатор.

Две реализации (обе раскладываются по порядкам условия k):

- *Паренклитика* — восстановление плотности $p(x)$, генеративная;
- *Синолитика* — модель $p(y \mid x)$, бинарная классификация, дискриминативная.

Схема метода SynoliticGraphClassifier

Граф объекта

Паренклитика (по плотности)

вес ребра:

$$w_{ij} = \log p(x_j | x_i, y=0)$$


обучение:

$$\max_{\phi} \sum_{x \in D_0} \sum_{i,j} \log p_{\phi_{ij}}(x_j | x_i, 0)$$

$k=0$: независимость

$k=1$: классич. паренклитика

$k \geq 2$: гиперрёбра



Паренклитика
по плотности

Синолитика
по меткам

Граф объекта
узлы —
признаки

Графовые
признаки
(опц.)

Финальная
модель
выдаёт
логарифмы

$\log p(x)$
 $\log p(y | x)$

сравнение

SGNN (бей-
злайн)
граф + GNN

$\hat{y}$

Синолитика (по меткам)

вес ребра: $w_{ij} = \log P(y=1 | x_i, x_j)$, $y | x_i, x_j \sim$

$\text{Bern}(p_{ij})$

$y | x_i, x_j \sim \text{Bern}(p_{ij})$

обучение: $\max_{\theta} \sum_{i,j} \sum_{(x,y)} [y \log f_{ij} + (1-y) \log(1-f_{ij})]$

$k=1$: наивный Байес

$k=2$: классич. синолитика

$k \geq 3$: гиперрёбра

Определения и обозначения

Паренклитика разлагает плотность $p(x)$, синологитика — условную модель $p(y | x)$; обе — по порядкам условия k .

Объекты и индексы

$x = (x_1, \dots, x_d) \in \mathbb{R}^d$ — объект, $y \in \{0, 1\}$ — метка

$[d] = \{1, \dots, d\}$; $I, S, T \subseteq [d]$ — подмножества

$x_I = (x_i)_{i \in I}$ — подвектор, $x_{-S} = (x_j)_{j \notin S}$
 $|I|$ — мощность; N — размер выборки, d — размерность

Распределения

$p(x)$ — плотность объекта

$p(y | x)$ — условная плотность

$p(x_i | x_I)$ — условная плотность признака

$C_d^r = \binom{d}{r}$ — биномиальный коэффициент

Ключевые величины

k — порядок условия (степень зависимости)

TC — полная корреляция, $TC(\cdot | \cdot)$ — условная

$\delta_k = \max_{|S|=k} TC(x_{-S} | x_S)$ — ошибка k -приближения

$\approx_k$ — приближение k -го порядка; D_{KL} — дивергенция КЛ

Предпосылки и ограничения

бинарная классификация, признаки

числовые

$p(x) > 0, p(x_i | x_I) > 0$ почти всюду

Силы вершин: не power-law

Теорема (распределение силы вершины)

Если

$$Z = X\theta + \xi, \quad \xi \sim \mathcal{N}(0, \sigma^2 I), \quad \hat{\theta} = (X^\top X)^{-1} X^\top Z, \quad H = X(X^\top X)^{-1} X^\top,$$

$$e_{ij}^k = x_j^k - \hat{a}_{ij} x_i^k - \hat{b}_{ij}, \quad w_{ij}^k = (e_{ij}^k)^2,$$

то

$$w_{ij}^k \sim \sigma^2 (1 - h_{kk}) \chi_1^2, \quad s^k(i) = \sum_{j \neq i} w_{ij}^k \sim \sigma^2 (1 - h_{kk}) \chi_{d-1}^2,$$

$$\mathbb{P}(s > x) \leq C e^{-cx} \implies \mathbb{P}(s > x) \not\sim x^{-\alpha}.$$

power-law: $\mathbb{P}(X > x) \sim x^{-\alpha}$ (тяжёлый хвост). $s \sim \chi_{d-1}^2$ — в приближении независимости остатков.

Теоремы о разложении по порядкам условия

Теорема T1 (паренклитическое разложение)

Если $p(x)$ — плотность на $\mathbb{R}^d$, то $\forall k \leq d-1$

$$\log p(x) = \sum_{r=0}^{k-1} \frac{\log F^{(r)}}{(r+1) C_d^{r+1}} + \frac{(d-k) \log F^{(k)}}{(k+1) C_d^{k+1}},$$
$$F^{(r)} = \prod_{i=1}^d \prod_{|I|=r, i \notin I} p(x_i | x_I).$$

Частные случаи:

$k=0$ — независимость

$k=1$ — классич.

паренклитика

$k \geq 2$ — гиперрѐбра

Симметризация по $d!$

перестановкам $\Rightarrow$ точные

биномиальные коэфф.

Теорема T2 (синолитическое разложение)

Если $p(y | x)$ — условная модель, то $\forall k \leq d$

$$\log p(y | x) \approx_k \sum_{t=0}^k c^{(k)}(t, d) \sum_{T \subseteq [d], |T|=t} \log p(y | x_T),$$
$$c^{(k)}(t, d) = \sum_{s=0}^{k-t} (-1)^s C_{d-t}^s.$$

Частные случаи:

$k=1$ — наивный Байес

$k=2$ — классич.

синолитика

$k \geq 3$ — гиперрѐбра

$c^{(k)}(t, d) = 0$ при $t > k$.

Строгая k -независимость вырождена

Определение (классическая паренклитическая k -независимость)

Случайный вектор X с плотностью $p > 0$ называется *строго k -независимым*, если для любого $S \subseteq [d]$, $|S| = k$, компоненты $\{X_j\}_{j \notin S}$ условно независимы при X_S :

$$p(x_{-S} \mid x_S) = \prod_{j \notin S} p(x_j \mid x_S).$$

Теорема ТЗ (вырожденность)

Если X строго k -независим при некотором $0 < k < d - 1$, то компоненты $X_1, \dots, X_d$ независимы в совокупности:

$$p(x) = \prod_{i=1}^d p(x_i).$$

Следствие. Строгое определение не различает порядки $k \in \{1, \dots, d - 2\}$ — его нужно ослабить.

Ослабление: (ε, k) -независимость через δ_k

Определение $((\varepsilon, k)$ -независимость)

Случайный вектор X называется (ε, k) -независимым, если $\delta_k(X) \leq \varepsilon$, где

$$\delta_k(X) := \max_{|S|=k} D_{\text{KL}}\left(p(x_{-S} \mid x_S) \parallel \prod_{j \notin S} p(x_j \mid x_S)\right).$$

Это максимальная условная полная корреляция остатка x_{-S} при x_S .

Теорема Т4 (свойства δ_k)


- 1 **Монотонность:** $\delta_{k+1} \leq \delta_k$ — больше условий, меньше остаточной зависимости.
- 2 **k -разложимость:** k -усечённая факторизация q_k (Теорема 1) приближает p : $D_{\text{KL}}(p \parallel q_k) \leq \delta_k$.
- 3 **Граничные случаи:** $\delta_0 = 0 \Leftrightarrow$ полная независимость; $\delta_{d-1} \equiv 0$.
- 4 **Невырожденность:** для каждого $k \in \{1, \dots, d-2\}$ существует распределение p с $0 < \delta_k < \delta_{k-1}$.

Демонстрация: δ_k на равнокоррелированной гауссовой модели

Модель: $X \sim \mathcal{N}(0, \Sigma)$, $\Sigma_{ii} = 1$, $\Sigma_{ij} = \rho$ при $i \neq j$

Точная формула ($r = \frac{\rho}{1+k\rho}$):



$$\delta_k(d, \rho) = -\frac{1}{2} \left[(d-k-1) \log(1-r) + \log(1+(d-k-1)r) \right].$$



Правило выбора k при известном ε

Идея. По заданному бюджету ε ищем минимальный порядок, который укладывается:

$$k_{\min}(\varepsilon, d, \rho) = \min\{k \in \{0, \dots, d-1\} : \delta_k(d, \rho) \leq \varepsilon\}.$$



- (а) тепловая карта $\delta_k(\rho, k)$ при $d = 20$ с уровнями ε (чёрные пунктиры) и долями снятия 50 % / 90 % / 99 % (белые сплошные).
- (б) $k_{\min}/d$ как функция ε при разных ρ и d .

Теорема Т5 (о слепоте): датасеты Parity- k и MixedParity

Теорема Т5 (о слепоте)

Если $X_j \sim U(-1, 1)$ i.i.d, индексы разбиты на блоки B_i длины k , а метка $Y = \text{sign}(\sum_i \text{sign}(\prod_{j \in B_i} X_j))$ (схема Parity- k), то для любого $I \subset [d]$ с $|I| = m < k$

$$P(Y = +1 | x_I) = \frac{1}{2},$$


т.е. любой набор из менее чем k признаков неинформативен.

Parity- k : AUC в зависимости от тестового k (порядка модели)
тризнаков во всех экспериментах | Серые столбцы — слепые порядки (тест. $k < k$ датасета) | Цветные — информативный по




Parity- k : слепота при $m < k$

Mixed Parity: AUC по тестовому k (порядку модели)
Серый — слеп | Полупрозрачный — видит k_1 компоненту | Темный — видит обе компоненты



MixedParity: ступеньки при $m = k_1, k_2$

Синтетические данные (pcg, xor, parity3)




ds	raw+XGB	syn mymodel	syn graph	SGNN/their	SGNN/our_syn
pcg	0.970	0.987	0.988	0.980	0.981
xor	0.974	0.901	0.908	0.866	0.815
parity3	0.887	0.559	0.543	0.587	0.548
macro	0.944	0.816	0.813	0.811	0.781

На pcg/xor (парный сигнал) наш syn graph + LR $\geq$ SGNN. На parity3 ($k=3$) все граф-методы ≈ 0.5 — теорема слепоты подтверждена.

Реальные данные: наш foundation бьёт всех, включая XGBoost

Synolitic + LogReg vs SGNN GATv2 (UCI/мед-датасеты, ROC-AUC, 5-fold CV)



Метод	raw+XGB	syn mymodel	SGNN sep.	SGNN found.	SGNN/our_syn found.
Macro (n=11)	0.812	0.814	0.759	0.825	0.831
plrx	0.365	0.429	0.472	0.589	0.652

Главный результат: SGNN/our_syn foundation = 0.831 — лучший на 11 датасетах, обгоняет и XGBoost (0.812), и foundation на их графе (0.825).

Выносятся на защиту

- 1 Разработана теория комбинаторного разложения многомерной плотности $\log p(x)$ и условной модели $\log p(y | x)$ по порядкам зависимости k (теоремы T1, T2). Разложения обобщают начальную паренклитику и синолитику на произвольный порядок и теоретически обосновывают эмпирически полезные признаки из прошлых работ.
- 2 Доказана вырожденность строгой k -независимости (T3) и предложено её невырожденное (ε, k) -ослабление через δ_k с доказанными свойствами (T4). Для гауссовой равнокоррелированной модели выведена замкнутая формула $\delta_k(d, \rho)$; определяющим оказывается относительное покрытие k/d , откуда — правило выбора k с ошибкой ε .
- 3 В серии экспериментов предложенные модели превзошли по AUC аналоги — SGNN-GATv2 (синолитическую графовую нейросеть с вниманием) и начальную синолитику — как на синтетических (Parity- k , MixedParity), так и на реальных (UCI) датасетах;

Публикация: «Overcoming the Curse of Dimensionality with Synolitic AI», *Technologies* 2026, 14, 84.

Выступления: доклад на 68-й научной конференции МФТИ.

Литература

- ❶ Tatiana Nazarenko, Harry J. Whitwell, Oleg Blyuss, Alexey Zaikin. “Parenclitic and synolytic networks revisited”. In: *Frontiers in Genetics* 12 (2021), Article 733783.
- ❷ Andrew Y. Ng, Michael I. Jordan. “On discriminative vs. generative classifiers: A comparison of logistic regression and naive Bayes”. In: *Advances in Neural Information Processing Systems* 14 (2001).
- ❸ Mikhail Krivososov, Tatiana Nazarenko, Vadim Ushakov, Daniil Vlasenko, Denis Zakharov, Shangbin Chen, Oleg Blyuss, Alexey Zaikin. “Analysis of Multidimensional Clinical and Physiological Data with Synolitical Graph Neural Networks”. In: *Technologies* 13.1 (2024).
- ❹ Alexey Zaikin, Mikhail Krivososov, Tatiana Nazarenko, Vadim Ushakov, Daniil Vlasenko, Denis Zakharov, Oleg Blyuss. “Overcoming the Curse of Dimensionality with Synolytic Graph Neural Networks”. In: *Technologies* 14.2 (2026), 84.
- ❺ Mikhail Krivososov, Tatiana Nazarenko, Maria Giulia Bacalini, Maria Vedunova, Claudio Franceschi, Alexey Zaikin. “A parenclitic network approach to a family-based cohort of patients with Down Syndrome”.