

Анализ данных большой размерности при малом размере выборки

Насыров Р.Р., Зайцев А.А.

МФТИ

23 мая 2026 г.

Тезисы, выносимые на защиту

Разработан теоретический фундамент паренклитических сетей:

- 1 Теор. обоснование полезности признаков, полученных эмпирическим путем авторами прошлых статей.
- 2 Теоремы о комбинаторном разложении 1) многомерной плотности 2) 1-мерной плотности по Мебиусу.
- 3 Доказано, что не существует "нетривиальных" распределений со степенью зависимости $0 < k < d - 1$.
- 4 Теорема о приближенном (ε, k) -разложении.
- 5 Выведена формула ошибки приближения $\delta_k(P)$ для гауссовской равнокоррелированной модели, проведен теор. анализ.

Разработаны практические инструменты:

- 1 *Parity-k*-распределение, демонстрирующее улучшение качества учитывающий степень зависимости моделей.
- 2 Гауссовый равнокорр. распределение для подбора параметров.
- 3 Сами паркнелитические и синологические модели.

Введение

Новизна

Цель исследования: предложить интерпретируемый способ решения задачи классификации в условиях недостатка данных/пропусков.

Задача: бинарная классификация многомерных данных.

Специфика данных: размерность данных достаточно большая по сравнению с их количеством: $D > N$, что ограничивает применимость стандартных моделей, т.к. может привести к их переобучению.

Предложено: обучить ансамбль бинарных классификаторов, восстановить плотность и вероятности с контролируемой степенью приближения.

Новизна: теор. фундамент приближенных разложений, проверка на спец. синтетических данных, теоретический trade-off $AUC \iff complexity$.

Введение

Паренклитические графы в бинарной классификации




Рис.: Пример создания
паренклитического графа




Рис.: Пример паренклитических
графов для разных классов
(вертикаль) и разных данных
(горизонталь).

Теоремы о разложении по порядкам условия

Паренклитика (разложение $\log p(x)$):

$$\log p(x) = \sum_{r=0}^{k-1} \frac{\log F^{(r)}}{(r+1) C_d^{r+1}} + \frac{(d-k) \log F^{(k)}}{(k+1) C_d^{k+1}},$$

$$F^{(r)} = \prod_{i=1}^d \prod_{|I|=r, i \notin I} p(x_i | x_I).$$

Синолитика (разложение $\log p(y | x)$):

$$\log p(y | x) \approx_k \sum_{t=0}^k c^{(k)}(t, d) \sum_{T \subseteq [d], |T|=t} \log p(y | x_T),$$

$$c^{(k)}(t, d) = \sum_{s=0}^{k-t} (-1)^s C_{d-t}^s.$$

Частные случаи:

$k=0$ — независимость

$k=1$ — классич. паренклитика

$k \geq 2$ — гиперрёбра

Частные случаи:

$k=1$ — наивный Байес

$k=2$ — классич. синолитика

$k \geq 3$ — гиперрёбра

Строгая k -независимость вырождена

Определение (классическая паренклитическая k -независимость)

Случайный вектор X называется *строго k -независимым*, если

$$\forall S \subseteq [d], |S| = k : \quad p(x_{-S} \mid x_S) = \prod_{j \notin S} p(x_j \mid x_S).$$

Теорема Т3 (вырожденность)

Пусть $p(x) > 0$ п. в. и $d \geq k + 2$. Тогда строгая k -независимость влечёт

$$p(x) = \prod_{i=1}^d p(x_i),$$

то есть полную независимость компонент.

Следствие: классическое определение не различает порядки $k \in \{1, \dots, d - 2\}$ и нуждается в ослаблении.

Ослабление: (ε, k) -независимость через δ_k

Определение $((\varepsilon, k)$ -независимость)

$$\delta_k(X) = \max_{|S|=k} D_{\text{KL}} \left(p(x_{-S} \mid x_S) \parallel \prod_{j \notin S} p(x_j \mid x_S) \right) \leq \varepsilon.$$

Теорема Т4 (свойства δ_k)


- ❶ **Монотонность:** $\delta_{k+1} \leq \delta_k$.
- ❷ **k -разложимость:** $D_{\text{KL}}(p \parallel q_k) \leq \delta_k$ для k -усечённой факторизации q_k .
- ❸ **Граничные случаи:** $\delta_0 = 0 \Leftrightarrow$ независимость; $\delta_{d-1} \equiv 0$.
- ❹ **Невырожденность:** $\forall k \in \{1, \dots, d-2\} \exists p: 0 < \delta_k < \delta_{k-1}$.

Демонстрация: δ_k на равнокоррелированной гауссовой модели

Модель: $X \sim \mathcal{N}(0, \Sigma)$, $\Sigma_{ii} = 1$, $\Sigma_{ij} = \rho$ при $i \neq j$

Точная формула ($r = \frac{\rho}{1+k\rho}$):



$$\delta_k(d, \rho) = -\frac{1}{2} \left[(d-k-1) \log(1-r) + \log(1+(d-k-1)r) \right].$$



Правило выбора k при известном ε

Идея. По заданному бюджету ε ищем минимальный порядок, который укладывается:

$$k_{\min}(\varepsilon, d, \rho) = \min\{k \in \{0, \dots, d-1\} : \delta_k(d, \rho) \leq \varepsilon\}.$$



- (а) тепловая карта $\delta_k(\rho, k)$ при $d = 20$ с уровнями ε (чёрные пунктиры) и долями снятия 50 % / 90 % / 99 % (белые сплошные).
- (б) $k_{\min}/d$ как функция ε при разных ρ и d .

Теорема слепоты: синтетические датасеты Parity- k и MixedParity


Генерация. $X_j \sim U(-1, 1)$ нез.; блоки B_i длины k ;

$$Y = \text{sign}\left(\sum_i \text{sign}\left(\prod_{j \in B_i} X_j\right)\right).$$

Теорема (о слепоте). $\forall I \subset [d], |I|=m < k : P(Y=+1 \mid \{X_j\}_{j \in I}) = \frac{1}{2}$.


MixedParity: склейка блоков разных порядков ($k_1 \neq k_2$) $\Rightarrow$ ступенчатый рост AUC при $m = \min k_i$, затем при $m = \max k_i$.

Parity- k : AUC в зависимости от тестового k (порядка модели)
 тризнаков во всех экспериментах | Серые столбцы — слепые порядки (тест. $k < k$ датасета) | Цветные — информативный по



Parity- k : слепота при $m < k$

Mixed Parity: AUC по тестовому k (порядку модели)
 Серый — слеп | Полупрозрачный — видит k_2 компоненты | Толстый — видит обе компоненты



MixedParity: ступеньки при $m = k_1, k_2$

Результаты экспериментов

Данные: $x_i \sim \mathcal{N}(0, \sigma^2)$; $x_i \leq k = 3$ предыдущих.




Рис.: $k = 3$.

Выводы:


- 1 $k = 1$ лучше на размерах выборок до $N \leq 75$. Это и есть случай паренклитических графов!
- 2 Модели выходят на плато качества.

Устойчивость моделей к деградации обучающих данных

Сетап: сферы $d = 10$, 5 классификаторов на raw vs MyModel-фичах ($k = 2$), 5 seed.


- **Шум** (доля повреждённых меток): MyModel сохраняет AUC дольше, чем raw.
- **Размер выборки n_{train}** : MyModel доминирует на малых n (где паренклитика теоретически оптимальна).

Устойчивость моделей к шуму в обучающих данных ($d = 7$, $k_{\text{true}} = 3$, $n_{\text{train}} = 5000$)



AUC vs доля шума в метках

Устойчивость моделей к уменьшению объёма данных ($d = 7$, $k_{\text{true}} = 3$)





AUC vs n_{train}

Реальные данные: лучший AUC и оптимальное k по парам моделей

Сетап: 13 реальных UCI/мед-датасетов ($d \leq 35$), StratifiedKFold(5);
|inner regressor| $\times$ |outer classifier|-сетка, варьируется k .

Что на графиках.

- Слева: лучший AUC для каждой пары (inner regressor $\times$ outer classifier).
- Справа: оптимальное k для каждой пары.
- Наблюдение: RandomForest как outer доминирует; для него разница между inner regressors < 2 п.п.



Личный вклад и направления развития

Личный вклад:

- Теоремы T1–T6: разложение $\log p(x)$, синолитика через Мёбиус, вырожденность строгой k -независимости, монотонность δ_k , слепота Parity- k , Markov-связь $\Omega = \Sigma^{-1}$.
- Алгоритм `MyModel(k)` / `MyModelSynolitic(k)` в Python.
- Эксперименты: устойчивость к деградации (шум, n_{train}) и tuning на 13 реальных UCI/мед-датасетах.

Будущая работа:

- Контрастивная паренклитика (реализована, нужны эксперименты на реальных данных).
- Байесовская спарсификация графа.
- GNN-расширение и связь с SGNN (Krivonosov, 2024).
- Теоретическое объяснение поведения метода на реальных табличных данных.

Литература

- ① Tatiana Nazarenko, Harry J. Whitwell, Oleg Blyuss, Alexey Zaikin. “Parenclitic and synolytic networks revisited”. In: *Frontiers in Genetics* 12 (2021), Article 733783.
- ② Andrew Y. Ng, Michael I. Jordan. “On discriminative vs. generative classifiers: A comparison of logistic regression and naive Bayes”. In: *Advances in Neural Information Processing Systems* 14 (2001).
- ③ Weikuan Jia, Meili Sun, Jian Lian, Sujuan Hou. “Feature dimensionality reduction: a review”. In: *Complex & Intelligent Systems* 8.3 (2022), pp. 2663–2693.
- ④ Mikhail Krivososov, Tatiana Nazarenko, Vadim Ushakov, Daniil Vlasenko, Denis Zakharov, Shangbin Chen, Oleg Blyuss, Alexey Zaikin. “Analysis of Multidimensional Clinical and Physiological Data with Synolitical Graph Neural Networks”. In: *Technologies* 13.1 (2024).
- ⑤ Mikhail Krivososov, Tatiana Nazarenko, Maria Giulia Bacalini, Maria Vedunova, Claudio Franceschi, Alexey Zaikin, Mikhail Ivanchenko. “A parenclitic network approach to a family-based cohort of patients with Down Syndrome”.